


TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT VĨNH LONG  
KHOA CÔNG NGHỆ THÔNG TIN



**BÁO CÁO**  
**MÔN: NGUYÊN LÝ MÁY HỌC**  
**ĐỀ TÀI: PHÂN TÍCH VÀ DỰ ĐOÁN**  
**BOUNDING BOX CỦA KHỐI U NÃO**  
**DỰA TRÊN ẢNH CHỤP CỘNG HƯỞNG TỪ**

Sinh viên thực hiện:

Lê Nguyễn Quang Bình 21022010

Nguyễn Hữu Thọ 21022008

Lớp: ĐH. KHMT 2021

Khóa: 2021 - 2025

Giáo viên hướng dẫn: TS. Phan Anh Cang

GV. Nguyễn Ngọc Hoàng Quyên

Vĩnh Long - Năm 2023

## NHẬN XÉT & ĐÁNH GIÁ ĐIỂM CỦA NGƯỜI HƯỚNG DẪN

Ý thức thực hiện: .....

.....

.....

.....

Nội dung thực hiện: .....

.....

.....

.....

Hình thức trình bày:.....

.....

.....

.....

Tổng hợp kết quả: .....

.....

.....

.....

☐ Tổ chức báo cáo trước hội đồng

☐ Tổ chức chấm thuyết minh

*Vĩnh Long, .... ngày .... tháng ... năm ....*

Người hướng dẫn

*(Ký và ghi rõ họ tên)*

## **LỜI CAM ĐOAN**

Chúng em, nhóm nghiên cứu, xin cam kết rằng nội dung trong bài báo cáo này là kết quả của quá trình nghiên cứu, tổng hợp và đánh giá cẩn thận và tỉ mỉ của chúng em. Chúng em đã tham khảo từ các nguồn tài liệu có nguồn gốc rõ ràng và đáng tin cậy, và chúng em đã chỉ sử dụng thông tin từ những nguồn đã được cho phép. Mọi nguồn được trích dẫn đều đã được ghi rõ ràng và đầy đủ trong bài báo cáo này.

Chúng em hiểu rằng việc cung cấp thông tin sai lệch có thể ảnh hưởng tới mục tiêu và tính xác thực của bài báo cáo này. Do đó, chúng em xin chịu trách nhiệm hoàn toàn nếu có bất kỳ thông tin sai lệch nào được phát hiện trong báo cáo của mình. Chúng em xin trân trọng cảm ơn và hy vọng bài báo cáo này sẽ đáp ứng được mọi yêu cầu và kỳ vọng.

Vĩnh Long, ngày 16 tháng 06 năm 2023

## LỜI CẢM ƠN

Đầu tiên và quan trọng nhất, chúng em xin gửi lời cảm ơn chân thành đến Trường Đại học Sư Phạm Kỹ Thuật Vĩnh Long vì đã tích cực đưa môn Nguyên lý Máy học vào chương trình giảng dạy. Trên hết, chúng em muốn bày tỏ lòng biết ơn sâu sắc đến Giảng viên TS. Phan Anh Cang và GV. Nguyễn Ngọc Hoàng Quyên, người đã tận tâm hướng dẫn chúng em trong suốt quá trình học tập và hoàn thành báo cáo học phần Nguyên lý Máy học với đề tài đầy thách thức: “Phát hiện khối u não từ ảnh chụp cộng hưởng từ của não”.

Khi tham gia lớp Nguyên lý Máy học do thầy/cô phụ trách, chúng em đã học hỏi được nhiều kiến thức bổ ích, thúc đẩy tinh thần học tập hiệu quả và nghiêm túc. Những kiến thức này không những quý báu mà còn là hành trang vững chắc cho chúng em tiến bước trong tương lai. Trong quá trình thực hiện báo cáo, các thầy đã rất nhiệt tình góp ý, giúp chúng em nâng cao chất lượng bài viết, đồng thời truyền đạt thêm nhiều kiến thức có ích trong suốt quá trình học và hoàn thành học phần Nguyên lý Máy học.

Bộ môn Nguyên lý Máy học là một môn học cực kỳ thú vị, bổ ích và thực tế. Nó không chỉ đảm bảo cung cấp đầy đủ kiến thức mà còn liên kết chặt chẽ với nhu cầu thực tế của sinh viên. Tuy nhiên, do hạn chế về kiến thức và khả năng tiếp thu thực tế, nhóm em còn gặp nhiều khó khăn.

Dù nhóm em đã cố gắng hết sức, nhưng không thể tránh khỏi những thiếu sót và những phần chưa chính xác trong báo cáo. Vì vậy, nhóm em rất mong nhận được sự đóng góp ý kiến nhiệt tình từ thầy/cô và các bạn, giúp nhóm em hoàn thiện hơn và rút kinh nghiệm cho những học phần sau.

Nhóm em xin chân thành cảm ơn thầy/cô!

## MỤC LỤC

LỜI CAM ĐOAN .....	I
LỜI CẢM ƠN.....	II
DANH MỤC BẢNG .....	VII
DANH MỤC HÌNH ẢNH ĐỒ THỊ .....	VIII
1. Lý do chọn đề tài. ....	1
2. Mục đích nghiên cứu. ....	1
3. Đối tượng nghiên cứu. ....	1
4. Phạm vi nghiên cứu. ....	1
5. Phương pháp nghiên cứu. ....	1
6. Ý nghĩa khoa học và ý nghĩa thực tiễn của dự đoán khối u não.....	2
6.1. Ý nghĩa khoa học.....	2
6.2. Ý nghĩa thực tiễn. ....	2
CHƯƠNG 1: CƠ SỞ KHOA HỌC CỦA ĐỀ TÀI .....	3
1.1. Cơ sở lý luận của đề tài .....	3
1.2. Cơ sở thực tiễn.....	3
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	5
2.1. Tìm hiểu về bệnh ung thư phổi.....	5
2.1.1. Định nghĩa về bệnh khối u nào.....	5
2.1.2. Nguyên nhân gây ra bệnh .....	5
2.1.3. Dấu hiệu bệnh ung thư phổi .....	5
2.1.4. Hậu quả khi bị bệnh ung thư phổi .....	7
2.2. Tổng quan về nguyên lý máy học.....	7
2.2.1. Nguyên lý máy học là gì?.....	7
2.2.2. Ứng dụng của nguyên lý máy học .....	8
2.3. Kỹ thuật deep learning.....	8
2.3.1. Khái niệm Deep learning.....	8
2.3.2. Ưu nhược điểm của kỹ thuật deep learning.....	9
2.3.3. Ứng dụng của deep learning.....	10
2.4. Tổng quan về ngôn ngữ python.....	10
2.5. Thư viện Tensorflow .....	10

2.6. Thư viện Keras .....	10
2.7. Mô hình MobileNet .....	11
2.8. Mô hình ResNet.....	12
2.9. Mô hình DenseNet.....	13
2.10. InceptionV3 .....	14
2.11. Đánh giá mô hình .....	15
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU .....	17
3.1. Đặc điểm dữ liệu.....	17
3.2. Mô hình nghiên cứu.....	18
3.3. Phương pháp nghiên cứu .....	18
3.3.1. Giai đoạn huấn luyện mô hình.....	18
3.3.2. Giai đoạn kiểm thử mô hình .....	19
3.4. Kích bản thực nghiệm.....	20
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THỰC NGHIỆM .....	21
4.1. Mô trường cài đặt .....	21
4.2. Các tham số của mô hình.....	21
4.3.1. Tham số mô hình ResNet101 .....	21
4.3.2. Tham số mô hình InceptionV3 .....	22
4.3.3. Tham số mô hình MobileNet.....	22
4.3.4. Tham số mô hình DenseNet121 .....	22
4.3.5. Kết quả nghiên cứu huấn luyện .....	22
4.3.5.1. Kích bản 1 (ResNet101) .....	22
4.3.5.2. Kích bản 2 (InceptionV3).....	23
4.3.5.3. Kích bản 3 (MobileNet).....	24
4.3.5.4. Kích bản 4 (DenseNet121) .....	24
4.3. Kết quả.....	25
4.3.1. Kết quả nghiên cứu huấn luyện .....	25
4.3.5.1. Độ đo chính xác huấn luyện .....	25
4.3.5.2. Độ đo Loss huấn luyện .....	26
4.3.5.3. Thời gian huấn luyện.....	26
4.3.2. Kết quả thực nghiệm .....	27

4.3.2.1. Độ đo chính xác thực nghiệm.....	27
4.3.2.2. Độ đo Loss thực nghiệm.....	27
4.3.2.3. Kết quả kiểm tra thực nghiệm .....	28
4.3.2.4. Kết quả kiểm tra thực nghiệm trên mạng ResNet101 .....	28
4.3.2.5. Kết quả kiểm tra thực nghiệm trên mạng InceptionV3 .....	28
4.3.2.6. Kết quả kiểm tra thực nghiệm trên mạng MobileNet.....	28
4.3.2.7. Kết quả kiểm tra thực nghiệm trên mạng DenseNet121 .....	29
4.4. Đánh giá.....	29
KẾT LUẬN HƯỚNG PHÁT TRIỂN .....	31
1. Kết luận.....	31
2. Hướng phát triển.....	31

## DANH MỤC CÁC CHỮ VIẾT TẮT

STT	Ký hiệu	Nội dung đầy đủ
1	AI	Artificial Intelligent
2	CPU	Central Processing Unit
3	CNN	Convolutional Neural Networks
4	GPU	Graphics Processing Unit



## **DANH MỤC BẢNG**

Bảng 3.1. Các kịch bản đề xuất và các tham số huấn luyện.....20

Bảng 4.1. Bảng tổng hợp kết quả so sánh đánh giá mô hình qua tập dữ liệu thực nghiệm29

## DANH MỤC HÌNH ẢNH ĐỒ THỊ

Hình 2.1. Hình sơ bộ Deep learning .....	8
Hình 2.2. Mô hình mạng MobileNet .....	11
Hình 2.3. Mô hình mạng ResNet.....	12
Hình 2.4. Mô hình mạng DenseNet.....	13
Hình 2.5. Mô hình mạng InceptionV3.....	14
Hình 2.6. Bảng ma trận nhầm lẫn (Confusion Matrix) .....	15
Hình 3.1. Tập dữ liệu huấn luyện và kiểm thử phân loại khối u não .....	17
Hình 3.2. Biểu đồ accuracy và loss của kịch bản 1 .....	22
Hình 3.3. Biểu đồ Ma trận nhầm lẫn kịch bản 1 .....	23
Hình 3.4. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 1 .....	23
Hình 3. 5. Biểu đồ accuracy và loss của kịch bản 2 .....	23
Hình 3. 6. Biểu đồ Ma trận nhầm lẫn kịch bản 2 .....	23
Hình 3. 7. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 2 .....	23
Hình 3. 8. Biểu đồ accuracy và loss của kịch bản 3 .....	24
Hình 3. 9. Biểu đồ Ma trận nhầm lẫn kịch bản 3 .....	24
Hình 3. 10. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 3 .....	24
Hình 3. 11. Biểu đồ accuracy và loss của kịch bản 4 .....	24
Hình 3. 12. Biểu đồ Ma trận nhầm lẫn kịch bản 4 .....	25
Hình 3. 13. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 4 .....	25
Hình 3. 14. Biểu đồ so sánh độ accuracy của các kịch bản đề xuất .....	25
Hình 3.15. Biểu đồ so sánh độ loss của các kịch bản đề xuất .....	26
Hình 3.16. Biểu đồ so sánh thời gian huấn luyện của các kịch bản đề xuất .....	26
Hình 3.17. Ảnh minh họa cho kết quả phân loại với kịch bản 1 .....	28
Hình 3.18. Ảnh minh họa cho kết quả phân loại với kịch bản 2 .....	28
Hình 3.19. Ảnh minh họa cho kết quả phân loại với kịch bản 3 .....	28
Hình 3. 20. Ảnh minh họa cho kết quả phân loại với kịch bản 4 .....	29

# MỞ ĐẦU

## 1. Lý do chọn đề tài.

Khối u não là sự phát triển bất thường của các tế bào trong não. Các khối u não có thể lành tính (không ung thư) hoặc ác tính (ung thư). Các khối u não lành tính không lan sang các bộ phận khác của cơ thể, nhưng chúng vẫn có thể gây ra vấn đề bằng cách chèn ép hoặc xâm lấn mô não bình thường. Các khối u não ác tính có thể lan sang các bộ phận khác của cơ thể và chúng thường gây tử vong. Vì vậy việc nghiên cứu máy học nhằm nhận diện khối u trong y học nhằm tiết kiệm nhân lực là điều vô cùng cần thiết.

## 2. Mục đích nghiên cứu.

Máy học giúp giảm thời gian chuẩn đoán và tăng độ chính xác từ đó có thể đưa ra các quyết định điều trị tốt hơn.

Khoanh vùng, chuẩn đoán kích thước cũng như hình dạng của khối u và để xác định chúng có lây lan sang các phần khác của não hay không.

Giúp đánh giá nguy cơ tái phát ung thư từ đó có thể lựa chọn cách điều trị tốt nhất.

## 3. Đối tượng nghiên cứu.

Trong nghiên cứu này, đối tượng chính là bộ dữ liệu ảnh chụp cộng hưởng từ của não, bao gồm cả ảnh của não bình thường và não có khối u.

## 4. Phạm vi nghiên cứu.

Trong nghiên cứu này, phạm vi nghiên cứu rất rộng lớn, bao gồm việc thu thập, xử lý và phân tích dữ liệu ảnh chụp cộng hưởng từ (MRI) của não. Phạm vi này cũng bao gồm việc thiết kế, huấn luyện và tối ưu hóa các mô hình máy học để phát hiện và phân loại khối u.

## 5. Phương pháp nghiên cứu.

### 5.1. Phương pháp nghiên cứu lý thuyết.

Học sâu là một loại máy học sử dụng mạng thần kinh nhân tạo để học từ dữ liệu. Các thuật toán học sâu đã được chứng minh là rất hiệu quả trong việc phân loại hình ảnh khối u não và chúng đang được sử dụng trong một số thử nghiệm lâm sàng.

## **5.2. Phương pháp nghiên cứu thực nghiệm.**

Dự đoán chéo tập dữ liệu được chia ngẫu nhiên thành tập huấn luyện và tập kiểm tra. Tập huấn luyện được sử dụng để huấn luyện thuật toán học máy và tập kiểm tra được sử dụng để đánh giá hiệu suất của thuật toán.

## **6. Ý nghĩa khoa học và ý nghĩa thực tiễn của dự đoán khối u não.**

### **6.1. Ý nghĩa khoa học.**

Việc phát hiện và chẩn đoán sớm các khối u não trong máy học, có khả năng cải thiện độ chính xác và hiệu quả của việc phát hiện khối u não, đồng thời giúp các bác sĩ đưa ra quyết định điều trị tốt hơn. Còn có thể được sử dụng để phân đoạn các khối u trong hình ảnh y tế giúp đo kích thước và hình dạng của khối u, đồng thời xác định xem chúng có lan sang các phần khác của não hay không. Ngoài ra có thể được sử dụng để dự đoán nguy cơ tái phát khối u cũng như có thể đưa ra các so sánh về phương pháp điều trị khác nhau

### **6.2. Ý nghĩa thực tiễn.**

Có thể giúp đưa ra dự đoán chính xác hơn so với con người, giảm thời gian phân tích ảnh từ đó giảm thời gian chuẩn đoán và điều trị. Việc phát hiện và chẩn đoán sớm các khối u não có thể giúp cải thiện kết quả của bệnh nhân, chẳng hạn như tăng tỷ lệ sống sót và giảm tác dụng phụ do điều trị. Còn có thể tự động hóa từ đó giảm được các chi phí chuẩn đoán.

## **7. Cấu trúc đề cương**

**Chương 1:** Tổng quan đề tài

**Chương 2:** Cơ sở khoa học của đề tài

**Chương 3:** Cơ sở lý thuyết

**Chương 4:** Phương pháp đề xuất

**Chương 5:** Kết quả nghiên cứu và thực nghiệm

**Chương 6:** Kết luận

# CHƯƠNG 1: CƠ SỞ KHOA HỌC CỦA ĐỀ TÀI

## 1.1. Cơ sở lý luận của đề tài

Cơ sở lý luận của đề dựa trên sự kết hợp giữa lĩnh vực y học hình ảnh, đặc biệt là ảnh chụp cộng hưởng từ, và lĩnh vực học máy, cụ thể là thị giác máy tính và học sâu.

Từ phía y học, ảnh chụp cộng hưởng từ đã được sử dụng rộng rãi để chụp hình ảnh chi tiết của cấu trúc trong não, bao gồm các khối u. Sử dụng các kỹ thuật tiên tiến, các bác sĩ có thể nhìn thấy các khối u, nhưng việc phân tích và xác định chính xác vị trí và kích thước của khối u đòi hỏi thời gian và kỹ năng chuyên môn cao.

Đó là nơi mà học máy, thị giác máy tính, và học sâu có thể đóng góp. Nhờ vào sự phát triển của các mô hình học sâu như CNN (Convolutional Neural Networks), R-CNN (Region-based Convolutional Neural Networks) hay YOLO (You Only Look Once), chúng ta có thể huấn luyện các mô hình để tự động nhận biết và vẽ bounding box xung quanh các khối u trên ảnh chụp cộng hưởng từ. Điều này không chỉ tiết kiệm thời gian cho các bác sĩ mà còn giúp tăng chất lượng và độ chính xác của việc phân loại và định vị khối u.

Vì vậy, cơ sở lý luận của đề tài này dựa trên việc kết hợp sự hiểu biết sâu sắc về y học hình ảnh và công nghệ học máy, tạo ra một giải pháp tiên tiến cho việc phân tích và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ.

## 1.2. Cơ sở thực tiễn

Cơ sở thực tiễn của đề tài rất rõ ràng và thiết thực, đặc biệt khi xét trong bối cảnh y học hiện đại và ngày càng phụ thuộc vào công nghệ.

Trong y học hình ảnh, việc xác định chính xác vị trí và kích thước của khối u não là yếu tố quan trọng đối với việc đưa ra chẩn đoán chính xác và lựa chọn phương pháp điều trị phù hợp. Hiện nay, việc này thường đòi hỏi sự can thiệp của các chuyên gia y học hình ảnh, nhưng quy trình này có thể mất thời gian và năng lực nhân sự.

Sự xuất hiện của các mô hình học máy trong việc dự đoán bounding box của khối u não từ ảnh chụp cộng hưởng từ có thể tạo ra sự thay đổi lớn trong ngành. Nhờ vào công nghệ này, chúng ta có thể tự động hóa phần lớn quy trình, giảm bớt gánh nặng cho các chuyên gia và tăng tốc độ và độ chính xác của việc chẩn đoán.

Đây không chỉ là một bước tiến lớn trong việc cung cấp chăm sóc sức khỏe chất lượng cao và kịp thời cho bệnh nhân, mà còn mở ra cánh cửa cho việc áp dụng công nghệ học máy vào nhiều lĩnh vực khác trong y học, từ việc phát hiện bệnh tật sớm cho đến việc tối ưu hóa quy trình điều trị. Đề tài này, do đó, không chỉ đáng giá vì mục tiêu nghiên cứu của nó, mà còn vì những tầm nhìn lớn hơn mà nó mang lại cho cộng đồng y học và công nghệ.

## CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

### 2.1. Tìm hiểu về bệnh ung thư phổi

#### 2.1.1. Định nghĩa về bệnh khối u não

Một khối u não (còn được gọi là khối u nội sọ) là một khối mô bất thường trong đó các tế bào phát triển và nhân lên không kiểm soát, dường như không được kiểm soát bởi các cơ chế kiểm soát các tế bào bình thường. Các khối u có thể lành tính (không phải ung thư) hoặc ác tính (ung thư).

#### 2.1.2. Nguyên nhân gây ra bệnh

- Tuổi tác: Nguy cơ phát triển khối u não tăng theo tuổi tác. Độ tuổi chẩn đoán trung bình là 65 tuổi. Tuy nhiên, u não có thể xảy ra ở mọi lứa tuổi, kể cả ở trẻ em.
- Giới tính: Đàn ông có khả năng phát triển khối u não cao hơn một chút so với phụ nữ.
- chủng tộc: U não phổ biến ở người da trắng hơn người da đen.
- Tiền sử gia đình: Những người có tiền sử gia đình mắc bệnh u não có nguy cơ mắc bệnh u não cao hơn.
- Tiếp xúc với bức xạ: Tiếp xúc với mức độ cao của bức xạ, chẳng hạn như từ liệu pháp bức xạ ion hóa, có thể làm tăng nguy cơ phát triển khối u não. Đây là một rủi ro hiếm gặp, nhưng điều quan trọng cần lưu ý là nó có tồn tại.
- Một số yếu tố môi trường: Tiếp xúc với một số yếu tố môi trường, chẳng hạn như một số hóa chất hoặc vi rút, cũng có thể làm tăng nguy cơ phát triển khối u não. Những yếu tố này không được hiểu rõ, nhưng chúng được cho là có vai trò trong một số ít trường hợp.

#### 2.1.3. Dấu hiệu bệnh ung thư phổi

- Nhức đầu: Nhức đầu là triệu chứng phổ biến nhất của khối u não. Chúng có thể tồi tệ hơn vào buổi sáng hoặc khi gắng sức. Những cơn đau đầu có thể khác với bất kỳ cơn đau đầu nào bạn từng mắc phải trước đây. Chúng có thể nghiêm trọng hơn, thường xuyên hơn hoặc kéo dài hơn.
- Buồn nôn và nôn: Buồn nôn và nôn có thể do tăng áp lực bên trong hộp sọ. Áp lực này có thể do chính khối u gây ra hoặc do sự phát triển của khối u.

- Co giật: Co giật có thể do khối u đè lên bề mặt não hoặc làm gián đoạn hoạt động điện trong não. Động kinh có thể ngắn hoặc kéo dài. Chúng có thể nhẹ hoặc nặng.
- Các vấn đề về thị lực: Các vấn đề về thị lực có thể do khối u đè lên dây thần kinh thị giác hoặc làm gián đoạn khả năng xử lý thông tin thị giác của não. Các vấn đề về thị lực có thể bao gồm nhìn mờ, nhìn đôi hoặc mất thị lực.
- Các vấn đề về thính giác: Các vấn đề về thính giác có thể do khối u đè lên dây thần kinh thính giác hoặc làm gián đoạn khả năng xử lý thông tin thính giác của não. Các vấn đề về thính giác có thể bao gồm mất thính giác, ù tai hoặc khó hiểu lời nói.
- Thay đổi tính cách: Thay đổi tính cách có thể do khối u đè lên thùy trán của não, nơi chịu trách nhiệm về tính cách và hành vi. Thay đổi tính cách có thể bao gồm thay đổi tâm trạng, cấu kình và thay đổi hành vi xã hội.
- Các vấn đề về trí nhớ: Các vấn đề về trí nhớ có thể do khối u đè lên thùy thái dương của não, chịu trách nhiệm về trí nhớ. Các vấn đề về trí nhớ có thể bao gồm khó nhớ các sự kiện gần đây, khó nhớ tên và khó học thông tin mới.
- Yếu hoặc liệt: Yếu hoặc liệt một bên cơ thể có thể do khối u đè lên vỏ não vận động. Điểm yếu hoặc tê liệt có thể từ nhẹ đến nặng.
- Chóng mặt hoặc các vấn đề về thăng bằng: Chóng mặt hoặc các vấn đề về thăng bằng có thể do các khối u đè lên hệ thống tiền đình của não, hệ thống chịu trách nhiệm về sự cân bằng. Chóng mặt hoặc các vấn đề về thăng bằng có thể khiến bạn khó đi lại, đứng hoặc ngồi thẳng.
- Các vấn đề về giọng nói: Các vấn đề về giọng nói có thể do khối u chèn ép lên các trung tâm nói của não. Các vấn đề về lời nói có thể bao gồm khó nói rõ ràng, khó hiểu lời nói và khó nuốt.
- Mệt mỏi: Mệt mỏi là triệu chứng phổ biến của u não. Nó có thể được gây ra bởi chính khối u hoặc do điều trị khối u. Mệt mỏi có thể gây khó khăn cho các hoạt động hàng ngày.



### **2.1.4. Hậu quả khi bị bệnh ung thư phổi**

- Tử vong: Nguy cơ tử vong do u não phụ thuộc vào loại khối u, kích thước khối u, tuổi và sức khỏe tổng thể của bệnh nhân. Ví dụ, nguy cơ tử vong do u nguyên bào thần kinh đệm, một loại u thần kinh đệm cao cấp, là khoảng 50% trong vòng 5 năm sau khi chẩn đoán. Tuy nhiên, nguy cơ tử vong do u màng não, một loại u thần kinh đệm cấp thấp, thấp hơn nhiều, khoảng 5% trong vòng 10 năm sau khi chẩn đoán.
- Tàn tật: Nguy cơ tàn tật do khối u não phụ thuộc vào vị trí của khối u, kích thước của khối u và loại khối u. Ví dụ, các khối u phát triển gần vỏ não vận động có thể gây tê liệt, trong khi các khối u phát triển gần trung tâm ngôn ngữ của não có thể gây ra các vấn đề về giọng nói.
- Tác dụng phụ của điều trị: Các tác dụng phụ của điều trị u não phụ thuộc vào loại điều trị được sử dụng. Ví dụ, phẫu thuật có thể gây đau, sưng và nhiễm trùng. Xạ trị có thể gây rụng tóc, mệt mỏi, buồn nôn và nôn. Hóa trị có thể gây rụng tóc, mệt mỏi, buồn nôn, nôn và suy giảm hệ miễn dịch.
- Khó khăn về tài chính: Chi phí điều trị u não có thể cao, đặc biệt nếu khối u lớn hoặc nếu bệnh nhân cần nhiều loại điều trị. Chi phí điều trị cũng có thể phụ thuộc vào bảo hiểm của bệnh nhân. Ví dụ, bệnh nhân có bảo hiểm tư nhân có thể phải trả một phần chi phí điều trị, trong khi bệnh nhân có Medicare hoặc Medicaid có thể không phải trả bất kỳ khoản nào.

## **2.2. Tổng quan về nguyên lý máy học**

### **2.2.1. Nguyên lý máy học là gì?**

Máy học (Machine Learning) là một nhánh của trí tuệ nhân tạo (Artificial Intelligence), tập trung vào việc xây dựng các mô hình và thuật toán cho phép máy tính "học" từ dữ liệu, thay vì được lập trình cụ thể để thực hiện một tác vụ nhất định. Mục tiêu chính của máy học là tạo ra mô hình dự đoán hoặc quyết định mà không cần sự can thiệp hay chỉ đạo rõ ràng từ con người.

## 2.2.2. Ứng dụng của nguyên lý máy học

Một số ứng dụng của nguyên lý máy học như:

**Phân loại hình ảnh:** Máy học được sử dụng để xây dựng mô hình có thể phân loại hình ảnh vào các loại khác nhau dựa trên nội dung của chúng. Ví dụ, các mô hình phân loại hình ảnh có thể được sử dụng để nhận dạng các đối tượng trong hình ảnh, nhận dạng khuôn mặt hoặc phát hiện các đối tượng cụ thể.

**Phân tích ngôn ngữ tự nhiên (NLP):** Máy học cũng được sử dụng trong việc phân tích và xử lý ngôn ngữ tự nhiên. Ví dụ, các mô hình máy học có thể được sử dụng để dịch ngôn ngữ, phân loại văn bản, phát hiện cảm xúc từ văn bản, hoặc tạo ra văn bản mới.

**Dự đoán thị trường tài chính:** Trong thị trường tài chính, máy học được sử dụng để xây dựng mô hình dự đoán giá cổ phiếu, dự đoán xu hướng thị trường hoặc phân tích rủi ro tài chính.

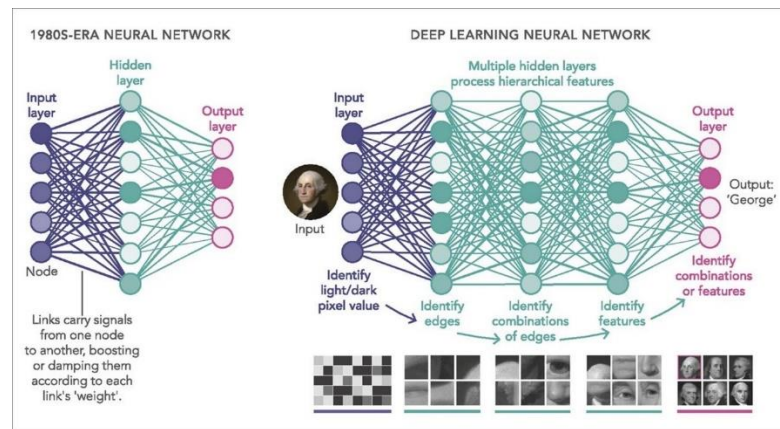
**Y tế:** Trong ngành y tế, máy học có thể được sử dụng để dự đoán bệnh dựa trên các triệu chứng, hình ảnh y tế, hoặc dữ liệu về lịch sử bệnh của bệnh nhân.

**Tự động hóa quảng cáo:** Trong quảng cáo, máy học có thể được sử dụng để tự động hóa việc nhắm mục tiêu quảng cáo dựa trên dữ liệu về hành vi của người dùng.

**Dự đoán khách hàng:** Máy học có thể được sử dụng để phân loại khách hàng, dự đoán hành vi mua hàng và tối ưu hóa chiến lược tiếp thị.

## 2.3. Kỹ thuật deep learning

### 2.3.1. Khái niệm Deep learning



Hình 2.1. Hình sơ bộ Deep learning

Deep learning là một lớp của học máy dựa trên mạng nơ-ron nhân tạo, sử dụng nhiều lớp để trích xuất đặc trưng cấp cao từ đầu vào thô. Thuật ngữ "deep" trong "deep learning" chỉ số lớp mà qua đó dữ liệu được biến đổi. Các hệ thống học sâu tự động học cách biến đổi dữ liệu đầu vào thành biểu diễn phức tạp và trừu tượng hơn ở mỗi lớp. Học sâu có thể được áp dụng trong các tác vụ học giám sát và không giám sát, và đã được sử dụng thành công trong nhiều lĩnh vực khác nhau, từ xử lý hình ảnh và nhận dạng giọng nói đến dịch máy và phân tích hình ảnh y tế

### **2.3.2. Ưu nhược điểm của kỹ thuật deep learning**

#### ***Ưu điểm của Deep Learning bao gồm:***

Hệ thống có khả năng tự động hóa việc học từ dữ liệu, giúp giảm thiểu quá trình tạo đặc trưng thủ công.

Deep learning cho phép tạo ra các mô hình phức tạp với độ chính xác cao, nhờ sử dụng nhiều lớp trong mạng neuron.

Khả năng xử lý các bài toán phức tạp, như nhận dạng hình ảnh, giọng nói, và xử lý ngôn ngữ tự nhiên.

Khả năng tiếp nhận và học từ lượng dữ liệu lớn, giúp tối ưu hóa hiệu quả trong việc học.

Khả năng học một cách tự động từ dữ liệu, điều này là một lựa chọn tốt so với học máy truyền thống dựa trên chuyên môn của con người.

Deep learning cho phép xem xét thế giới dưới dạng cấu trúc không giám sát.

#### ***Tuy nhiên, Deep Learning cũng có một số nhược điểm như:***

Deep Learning thường khó so sánh với các phương pháp tạo ra thủ công.

Rất khó để đánh giá hiệu suất của nó trong các ứng dụng thực tế; các ứng dụng có thể khác biệt lớn từ ứng dụng này sang ứng dụng khác.

Cần một lượng dữ liệu lớn để huấn luyện, điều này đôi khi không phù hợp với các tình huống mà dữ liệu có sẵn là hạn chế.

Tốc độ học tương đối chậm so với các phương pháp học máy khác.

Cần nhiều tài nguyên tính toán và bộ nhớ, đặc biệt là khi huấn luyện với các mô hình lớn và dữ liệu lớn.

Yêu cầu sử dụng các kỹ thuật tối ưu hóa tiên tiến, và những kỹ thuật này cần phải được tích hợp để có được kết quả tốt

### **2.3.3. Ứng dụng của deep learning**

#### **Một số ứng dụng của deep learning như:**

Trong y tế: Học sâu được sử dụng trong phân loại hình ảnh y tế, phân tích gen, dự đoán bệnh, và nhiều ứng dụng khác trong y học.

Trong ngành công nghiệp ô tô: Các công ty như Tesla đang sử dụng học sâu để phát triển xe tự lái. Học sâu giúp các hệ thống nhận dạng đối tượng, dẫn đường và tránh va chạm.

Trong giáo dục: Học sâu cũng được sử dụng để phát triển các hệ thống giáo dục cá nhân hóa và cải thiện kết quả học tập

### **2.4. Tổng quan về ngôn ngữ python**

Python là ngôn ngữ lập trình máy tính bậc cao thường được sử dụng để xây dựng trang web và phần mềm, tự động hóa các tác vụ và tiến hành phân tích dữ liệu. Python là ngôn ngữ có mục đích chung, nghĩa là nó có thể được sử dụng để tạo nhiều chương trình khác nhau và không chuyên biệt cho bất kỳ vấn đề cụ thể nào.

### **2.5. Thư viện Tensorflow**

TensorFlow là một thư viện phần mềm nguồn mở và miễn phí dành cho máy học và trí tuệ nhân tạo. Nó có thể được sử dụng trong nhiều nhiệm vụ nhưng tập trung đặc biệt vào đào tạo và suy luận về mạng lưới thần kinh sâu.

### **2.6. Thư viện Keras**

Keras là một thư viện học sâu mã nguồn mở trong Python được phát triển nhằm tạo ra một cách tiếp cận dễ dàng và thuận tiện để xây dựng và huấn luyện các mô hình học sâu. Nó cung cấp một giao diện trực quan và dễ sử dụng, tập trung vào việc tối ưu hóa trải nghiệm người dùng và giúp họ nhanh chóng triển khai các mô hình học sâu.

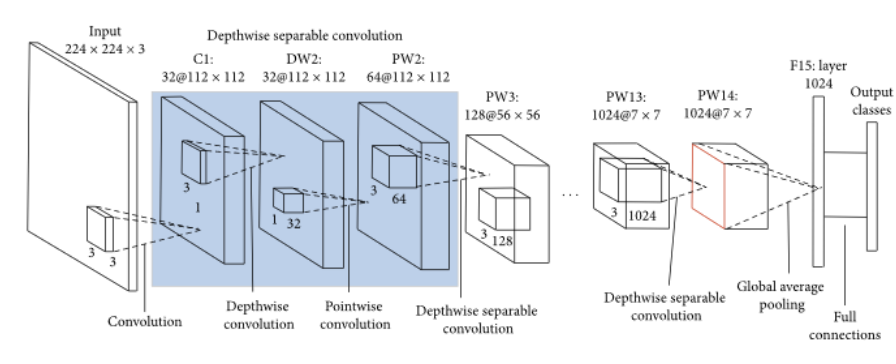
Keras hỗ trợ nhiều kiến trúc mạng nơ-ron khác nhau, bao gồm cả các mạng nơ-ron truyền thẳng (feed-forward), mạng nơ-ron hồi quy (recurrent neural networks - RNNs), và

mạng nơ-ron tích chập (convolutional neural networks - CNNs). Thư viện này cung cấp các công cụ để làm việc với dữ liệu, định nghĩa và huấn luyện mô hình, và cuối cùng là đánh giá và tối ưu hóa mô hình.

Một điểm mạnh của Keras là khả năng tương thích với các thư viện học sâu phổ biến khác như TensorFlow, Theano, hoặc CNTK, giúp người dùng có thể dễ dàng di chuyển giữa các thư viện này mà không cần phải thay đổi code đáng kể. Điều này giúp Keras trở thành lựa chọn hàng đầu cho nhiều nhà khoa học dữ liệu và nhà nghiên cứu học máy.

Cuối cùng, Keras cung cấp một lượng lớn tài liệu hướng dẫn và ví dụ, giúp cho việc học và sử dụng thư viện này trở nên dễ dàng hơn, ngay cả với những người mới học lập trình.

## 2.7. Mô hình MobileNet




Hình 2.2. Mô hình mạng MobileNet

MobileNet là kiến trúc mạng thần kinh tích chập (CNN) do Google đề xuất vào năm 2017. Đây là một loại CNN được thiết kế nhẹ và hiệu quả, phù hợp với thiết bị di động và thiết bị nhúng.

MobileNet đã được chứng minh là đạt được kết quả tiên tiến trong nhiều tác vụ phân loại hình ảnh, đồng thời hiệu quả hơn đáng kể so với CNN truyền thống. Ví dụ: MobileNet-V2 đạt tỷ lệ lỗi trong top 5 là 21,9% trên bộ dữ liệu ImageNet, trong khi chỉ sử dụng 1,4 triệu tham số. Đây là số tham số ít hơn đáng kể so với các CNN tiên tiến khác, chẳng hạn như ResNet-50, có 25,6 triệu tham số.

MobileNet là một kiến trúc CNN mạnh mẽ và linh hoạt, có thể được sử dụng cho nhiều nhiệm vụ khác nhau. Nó đặc biệt phù hợp với các nhiệm vụ phân loại hình ảnh, nhưng nó cũng có thể được sử dụng cho các nhiệm vụ khác như phát hiện và phân đoạn đối tượng.

## 2.8. Mô hình ResNet



Hình 2.3. Mô hình mạng ResNet

Residual Networks (ResNets) là một loại mô hình học sâu thường được sử dụng để phân loại hình ảnh và các tác vụ thị giác máy tính khác. Chúng được giới thiệu lần đầu tiên vào năm 2015 bởi Kaiming He, Xiangyu Zhang, Shaoqing Ren và Jian Sun trong bài báo "Deep Residual Learning for Image Recognition" của họ.

ResNets hoạt động bằng cách sử dụng một loạt "Residual block" để tìm hiểu các chức năng còn lại được thêm vào đầu vào của mạng. Điều này cho phép mạng học các tính năng phức tạp hơn bằng cách xây dựng trên các tính năng đơn giản hơn đã được học.

Input:  $x$

Residual block:


- \* Conv2d: 3x3 kernel, 64 filters
- \* Batch normalization
- \* ReLU activation
- \* Conv2d: 3x3 kernel, 64 filters
- \* Batch normalization
- \* ReLU activation
- \* Identity

Output:  $F(x) = H(x) + x$

ResNets đã được chứng minh là rất hiệu quả để phân loại hình ảnh. Trong Thử thách nhận dạng hình ảnh quy mô lớn ImageNet (ILSVRC) năm 2015, một mô hình ResNet có tên ResNet-50 đã đạt được tỷ lệ lỗi nằm trong top 5 là 3,57%, tốt hơn đáng kể so với bất kỳ mô hình nào khác đã được gửi tham gia cuộc thi.

ResNets cũng đã được sử dụng cho các tác vụ thị giác máy tính khác, chẳng hạn như phát hiện đối tượng và phân đoạn ngữ nghĩa. Chúng cũng đã được sử dụng cho các nhiệm vụ xử lý ngôn ngữ tự nhiên, chẳng hạn như phân loại văn bản và dịch máy.

## 2.9. Mô hình DenseNet



Hình 2.4. Mô hình mạng DenseNet

DenseNet là một kiến trúc mạng thần kinh tích chập (CNN) được đề xuất vào năm 2016 bởi Huang et al. Nó là một loại CNN sử dụng các kết nối dày đặc giữa các lớp. Điều này có nghĩa là mỗi lớp trong mạng được kết nối với tất cả các lớp trước đó, cũng như với lớp tiếp theo. Mẫu kết nối này cho phép DenseNets tìm hiểu các tính năng mạnh mẽ hơn so với CNN truyền thống.

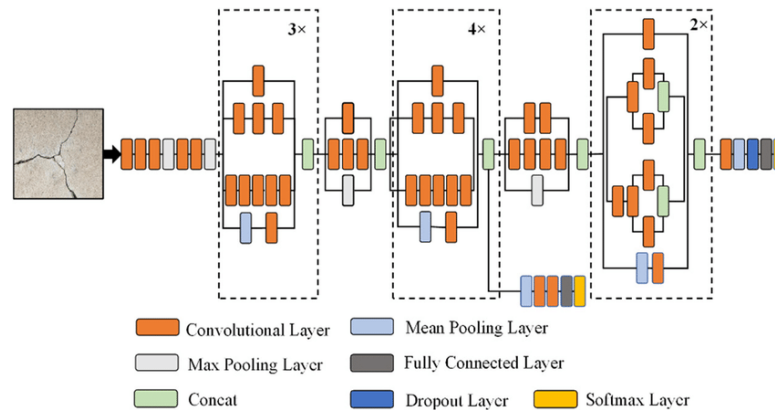
DenseNets có một số lợi thế so với CNN truyền thống. Đầu tiên, chúng làm giảm bớt vấn đề biến mất-gradient. Đây là một vấn đề xảy ra trong các mạng thần kinh sâu, trong đó độ dốc của hàm mất mát đối với trọng số của mạng có thể trở nên rất nhỏ, khiến mạng khó học. DenseNets giảm thiểu vấn đề này bằng cách cho phép thông tin truyền qua mạng dễ dàng hơn.

Thứ hai, DenseNets tăng cường tuyên truyền tính năng. Điều này có nghĩa là các tính năng được học bởi các lớp đầu tiên trong mạng được truyền tới các lớp sau, nơi chúng có thể được sử dụng để cải thiện độ chính xác của mạng.

Thứ ba, DenseNets khuyến khích sử dụng lại tính năng. Điều này có nghĩa là các tính năng được học bởi một lớp trong mạng có thể được sử dụng lại bởi các lớp khác, điều này có thể giúp giảm số lượng tham số trong mạng.

DenseNets đã được chứng minh là đạt được kết quả tiên tiến trong nhiều nhiệm vụ phân loại hình ảnh. Ví dụ: DenseNet-121 đạt được tỷ lệ lỗi top 5 là 22,5% trên bộ dữ liệu ImageNet, tốt hơn so với tỷ lệ lỗi top 5 là 23,3% do ResNet-152 đạt được.

## 2.10. InceptionV3



Hình 2.5. Mô hình mạng InceptionV3

Inception v3 là kiến trúc mạng thần kinh tích chập (CNN) được Google phát triển vào năm 2015. Đây là thế hệ thứ ba của dòng CNN Inception và được thiết kế để cải thiện hiệu suất của các phiên bản tiền nhiệm đồng thời giảm số lượng tham số yêu cầu.

Inception v3 đạt được điều này bằng cách sử dụng một số kỹ thuật mới, bao gồm:

- Tích chập 7x7 thừa số: Các tích chập này được chia thành hai tích chập 3x3, giúp giảm số lượng tham số cần thiết trong khi vẫn duy trì độ chính xác.
- Các kết nối còn lại: Các kết nối này cho phép thông tin truyền qua mạng dễ dàng hơn, giúp ngăn chặn việc trang bị quá mức.
- Bộ phân loại phụ trợ: Các bộ phân loại này được thêm vào mạng ở các lớp trung gian, giúp cải thiện độ chính xác của phân loại cuối cùng.

Inception v3 được đào tạo trên bộ dữ liệu ImageNet, chứa hơn 1,2 triệu hình ảnh được gắn nhãn với 1.000 danh mục khác nhau. Nó đạt được tỷ lệ lỗi trong top 5 là 23,8%, đây là một cải tiến đáng kể so với các CNN trước đó.

Inception v3 đã được sử dụng cho nhiều tác vụ khác nhau, bao gồm phân loại hình ảnh, phát hiện đối tượng và nhận dạng cảnh. Nó cũng đã được sử dụng để phát triển các kỹ thuật hình ảnh y tế mới và để cải thiện hiệu suất của ô tô tự lái.



## 2.11. Đánh giá mô hình

Đánh giá mô hình là quá trình đánh giá hiệu suất của một mô hình học máy. Nó được thực hiện bằng cách đánh giá mô hình trên một bộ kiểm tra đã tổ chức, đây là một bộ dữ liệu không được sử dụng để huấn luyện mô hình. Mục tiêu của việc đánh giá mô hình là xác định mức độ tổng quát của mô hình đối với dữ liệu mới.

Có một số chỉ số khác nhau có thể được sử dụng để đánh giá một mô hình máy học. Một số chỉ số phổ biến bao gồm:

	Predicted <b>0</b>	Predicted <b>1</b>
Actual <b>0</b>	TN	FP
Actual <b>1</b>	FN	TP

Hình 2.6. Bảng ma trận nhầm lẫn (Confusion Matrix)

- Accuracy: Độ chính xác được sử dụng trong các bài toán phân loại để cho biết tỷ lệ phần trăm các dự đoán chính xác được thực hiện bởi một mô hình. Điểm chính xác trong học máy là một chỉ số đánh giá đo lường số lượng dự đoán chính xác do một mô hình đưa ra so với tổng số dự đoán được đưa ra. Nhóm em tính toán nó bằng cách chia số dự đoán đúng cho tổng số dự đoán.

$$Accuracy = \frac{Số\ lượng\ dự\ đoán\ đúng(TP + TN)}{Tổng\ số\ lượng\ dự\ đoán(Total)}$$

TP: True Positive

TN: True Negative

FP: False Positive

FN: False Negative

- Precision: Khả năng của một mô hình phân loại chỉ xác định các điểm dữ liệu có liên quan. Về mặt toán học, độ chính xác là số lần khẳng định đúng chia cho tổng khẳng định đúng cộng với số lần khẳng định sai.

$$Precision = \frac{Số\ lượng\ khẳng\ định\ đúng(TP)}{Khẳng\ định\ đúng + khẳng\ định\ sai(TP + FP)}$$

- Recall: Khả năng của một mô hình tìm thấy tất cả các trường hợp có liên quan trong một tập dữ liệu. Về mặt toán học, định nghĩa Recall là số lần khẳng định đúng chia cho số lần khẳng định đúng cộng với số lần phủ định sai.


$$Recall = \frac{Số\ lượng\ khẳng\ định\ đúng(TP)}{Khẳng\ định\ đúng + phủ\ định\ sai(TP + FN)}$$

- F1 Score: là một chỉ số đánh giá học máy để đo lường độ chính xác của mô hình. Nó kết hợp điểm chính xác và thu hồi của một mô hình. Số liệu về độ chính xác tính toán số lần một mô hình đưa ra dự đoán chính xác trên toàn bộ tập dữ liệu.

$$F1\ Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

## CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

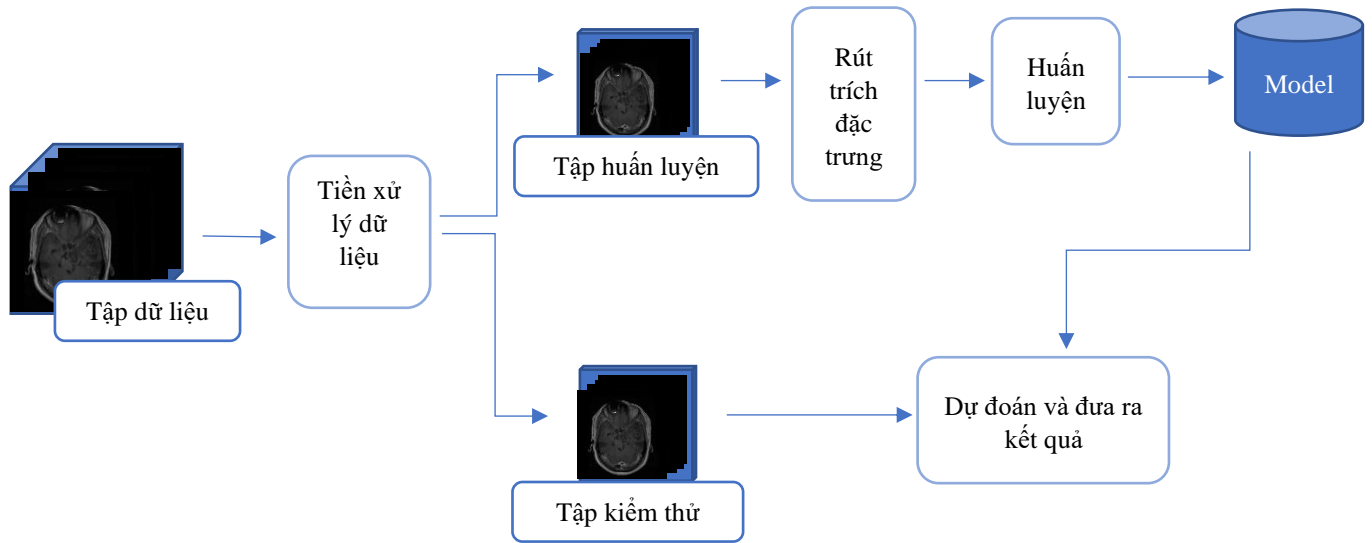
### 3.1. Đặc điểm dữ liệu



*Hình 3.1. Tập dữ liệu huấn luyện và kiểm thử phân loại khối u não*

Chất lượng của mô hình phụ thuộc rất lớn vào chất lượng và số lượng của dữ liệu thực nghiệm. Tập dữ liệu về khối u não là tập hợp dữ liệu được sử dụng để huấn luyện và đánh giá các mô hình máy học nhằm phát hiện khối u não. Bộ dữ liệu này chứa ảnh chụp cộng hưởng từ của bệnh nhân bị u não cho biết trí của khối u. Tập dữ liệu hiện tại bao gồm 2 thành phần chính là ảnh não có khối u (tumor) và ảnh não bình thường. Tập dữ liệu được chụp từ nhiều hướng khác nhau chủ yếu là từ trên xuống nhằm có đa góc nhìn về dữ liệu.

### 3.2. Mô hình nghiên cứu



Ở mô hình trên đầu tiên sau khi có đủ tập dữ liệu, nhóm em đã tiến hành tiền xử lý dữ liệu để đảm bảo đầu vào cho mô hình sắp tiến hành huấn luyện, sau đó sẽ bắt đầu chia dữ liệu thành hai tập là train và test và sẽ đều có 2 lớp là não bình thường và não có chứa khối u. Tập dữ liệu train sẽ được đưa vào và tiến hành rút trích đặc trưng, các đặc trưng sẽ đưa vào huấn luyện cho mô hình. Các tham số sẽ được hiệu chỉnh nhằm tối ưu hóa cũng như giúp mô hình cải thiện khả năng học tập. Sau khi huấn luyện mô hình sẽ được đưa đi kết hợp với tập kiểm thử để dự đoán, phân loại và xác định khối u dựa trên những đặc trưng mà mô hình vừa học từ tập dữ liệu.

### 3.3. Phương pháp nghiên cứu

#### 3.3.1. Giai đoạn huấn luyện mô hình

Giai đoạn huấn luyện mô hình trong dự án "Phân tích và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ" chính là trái tim của quá trình xây dựng mô hình. Đây là giai đoạn mà nhóm em sẽ "dạy" mô hình cách nhận biết và dự đoán vị trí cũng như kích thước của bounding box bao quanh khối u.

Trong giai đoạn này, nhóm em sẽ sử dụng một tập hợp lớn dữ liệu huấn luyện, bao gồm các ảnh chụp cộng hưởng từ của não bộ cùng với thông tin về vị trí và kích thước của bounding box quanh khối u. Mô hình sẽ "học" từ dữ liệu này thông qua việc tinh chỉnh các tham số của nó để giảm thiểu sai số giữa kết quả dự đoán và thực tế.

Nhóm em cũng sẽ sử dụng các kỹ thuật huấn luyện như đánh giá trên tập validation, early stopping, và regularization để tránh overfitting và giúp mô hình có khả năng tổng quát hóa tốt hơn trên dữ liệu chưa từng gặp.

Với mỗi epoch trong quá trình huấn luyện, mô hình sẽ ngày càng cải thiện khả năng dự đoán của mình. Tuy nhiên, điều quan trọng là phải cẩn thận lựa chọn thời điểm dừng lại để mô hình không "học quá" và trở nên quá phức tạp, điều này có thể dẫn đến việc mô hình hoạt động kém khi gặp dữ liệu mới trong giai đoạn kiểm thử.

Giai đoạn huấn luyện mô hình là một quá trình cần sự kiên nhẫn và thận trọng, nhưng nó là bước tiến quan trọng để nhóm em có thể xây dựng một mô hình hiệu quả trong việc phân tích và dự đoán bounding box của khối u não.

### **3.3.2. Giai đoạn kiểm thử mô hình**

Giai đoạn kiểm thử mô hình là một bước quan trọng và không thể thiếu trong đề tài "Phân tích và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ". Đây là giai đoạn cuối cùng trong quy trình xây dựng mô hình, nhằm đánh giá và đảm bảo hiệu suất, độ chính xác của mô hình trên dữ liệu không tham gia vào quá trình huấn luyện.

Trong giai đoạn này, nhóm em sẽ sử dụng một bộ dữ liệu kiểm thử độc lập, chưa từng được mô hình "nhìn thấy" trong quá trình huấn luyện. Dữ liệu này được sử dụng để đánh giá mô hình dựa trên các chỉ số như độ chính xác, độ mất mát, v.v. Đặc biệt, trong bối cảnh của dự án này, nhóm em chú trọng vào việc đánh giá khả năng dự đoán chính xác vị trí và kích thước của bounding box bao quanh khối u.

Qua giai đoạn kiểm thử, nhóm em đã có thể phát hiện được những vấn đề tiềm ẩn của mô hình, như overfitting (mô hình quá khớp với dữ liệu huấn luyện và thể hiện kém khi gặp dữ liệu mới), underfitting (mô hình không học được đủ từ dữ liệu huấn luyện), hoặc bias (mô hình có xu hướng ưu tiên nhận biết một số loại khối u hơn các loại khác).

Cuối cùng, những kết quả từ giai đoạn kiểm thử mô hình sẽ là cơ sở quan trọng để quyết định liệu mô hình đã sẵn sàng để triển khai vào thực tế hay không, và định hình những bước tiếp theo của đề tài trong tương lai.

### 3.4. Kịch bản thực nghiệm

*Bảng 3.1. Các kịch bản đề xuất và các tham số huấn luyện*

<b>KỊCH BẢN</b>	<b>MẠNG</b>	<b>Learning rate</b>	<b>Epochs</b>	<b>batch_size</b>	<b>Num Classes</b>
1	ResNet101	0,0001	200	16	2
2	InceptionV3				
3	MobileNet				
4	DenseNet121				

## CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THỰC NGHIỆM

### 4.1. Môi trường cài đặt



Kaggle là một nền tảng dành cho việc học và thực hành khoa học dữ liệu và học máy. Nó được thành lập bởi Anthony Goldbloom và Ben Hamner vào năm 2010, và sau đó được Google mua lại vào năm 2017. Kaggle cung cấp một cộng đồng nơi các nhà khoa học dữ liệu và máy học có thể tương tác, chia sẻ ý tưởng, thực hiện các dự án, và tham gia vào các cuộc thi khoa học dữ liệu.

### 4.2. Các tham số của mô hình

Các mô hình ResNet101, InceptionV3, MobileNet và DenseNet121 có các tham số riêng biệt. Dưới đây là một số thông tin về các tham số quan trọng của mỗi mô hình:

#### 4.3.1. Tham số mô hình ResNet101

- Hàm Mô hình: `tf.keras.applications.ResNet101`

- Tham số đầu vào:

- o `weights="imagenet"`: Trọng số được đào tạo trước trên tập dữ liệu ImageNet, một tập dữ liệu lớn bao gồm hơn một triệu hình ảnh và 1000 lớp đối tượng khác nhau. Việc sử dụng trọng số này giúp mô hình học được các đặc trưng chung cho hầu hết các bài toán thị giác máy tính.

- o `include_top=False`: Không muốn bao gồm phần phân loại (tức là các lớp hoàn toàn kết nối ở cuối của mạng) của mô hình MobileNet gốc. Điều này cho phép thêm các lớp phân loại của riêng, phù hợp với nhiệm vụ cụ thể.

- o `input_tensor=Input(shape=(224, 224, 3))`: Đây là kích thước đầu vào của mạng. Ở đây, mỗi hình ảnh sẽ có kích thước 224x224 pixel và 3 kênh màu (RGB).

- o `trainLabels, testLabels`: Nhãn phân loại cho dữ liệu huấn luyện và kiểm tra. Các nhãn này sẽ được sử dụng để đào tạo và kiểm tra mô hình.

- `trainBBoxes`, `testBBoxes`: Bounding boxes cho dữ liệu huấn luyện và kiểm tra. Các bounding box này sẽ được sử dụng để đào tạo và kiểm tra phần dự đoán bounding box của mô hình.
- `trainImages`, `testImages`: Hình ảnh dùng cho việc đào tạo và kiểm tra mô hình.
- `MyBatch`: Kích thước batch sẽ được sử dụng khi đào tạo mô hình. Mỗi batch sẽ chứa một số lượng nhất định hình ảnh và nhãn tương ứng.
- `MyEpoch`: Số lượng epoch, hay vòng lặp qua toàn bộ tập dữ liệu huấn luyện, mà mô hình sẽ thực hiện trong quá trình đào tạo.
- `learning_rate=0.0001`: Tốc độ học cho thuật toán tối ưu hóa Adam. Tốc độ học xác định cỡ bước mà mô hình sẽ thực hiện để cập nhật trọng số trong mỗi lần đào tạo.

#### 4.3.2. Tham số mô hình InceptionV3

- Hàm Mô hình: `tf.keras.applications.InceptionV3`
- Tham số đầu vào: Như ResNet101

#### 4.3.3. Tham số mô hình MobileNet


- Hàm Mô hình: `tf.keras.applications.MobileNet`
- Tham số đầu vào: Như ResNet101

#### 4.3.4. Tham số mô hình DenseNet121

- Hàm Mô hình: `tf.keras.applications.DenseNet121`
- Tham số đầu vào: Như ResNet101


#### 4.3.5. Kết quả nghiên cứu huấn luyện

##### 4.3.5.1. Kịch bản 1 (ResNet101)




Hình 3.2. Biểu đồ accuracy và loss của kịch bản 1







Hình 3.3. Biểu đồ Ma trận nhầm lẫn kịch bản 1

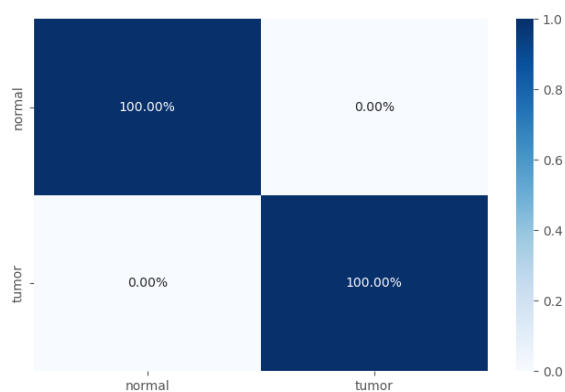


Hình 3.4. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 1


#### 4.3.5.2. Kịch bản 2 (InceptionV3)



Hình 3. 5. Biểu đồ accuracy và loss của kịch bản 2




Hình 3. 6. Biểu đồ Ma trận nhầm lẫn kịch bản 2




Hình 3. 7. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 2

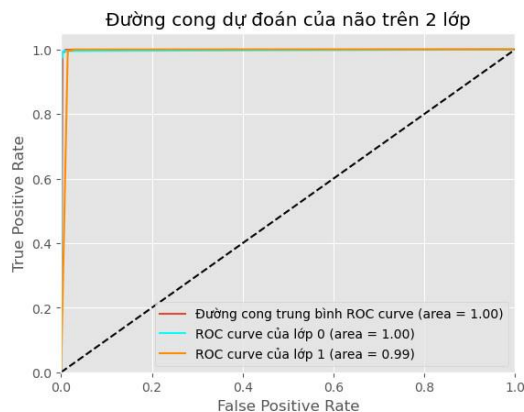
#### 4.3.5.3. Kịch bản 3 (MobileNet)



Hình 3. 8. Biểu đồ accuracy và loss của kịch bản 3




Hình 3. 9. Biểu đồ Ma trận nhầm lẫn kịch bản 3




Hình 3. 10. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 3


#### 4.3.5.4. Kịch bản 4 (DenseNet121)



Hình 3. 11. Biểu đồ accuracy và loss của kịch bản 4



Hình 3. 12. Biểu đồ Ma trận nhầm lẫn kịch bản 4




Hình 3. 13. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 4

### 4.3. Kết quả


#### 4.3.1. Kết quả nghiên cứu huấn luyện

##### 4.3.5.1. Độ đo chính xác huấn luyện




Hình 3. 14. Biểu đồ so sánh độ accuracy của các kịch bản đề xuất

#### 4.3.5.2. Độ đo Loss huấn luyện



Hình 3.15. Biểu đồ so sánh độ loss của các kịch bản đề xuất

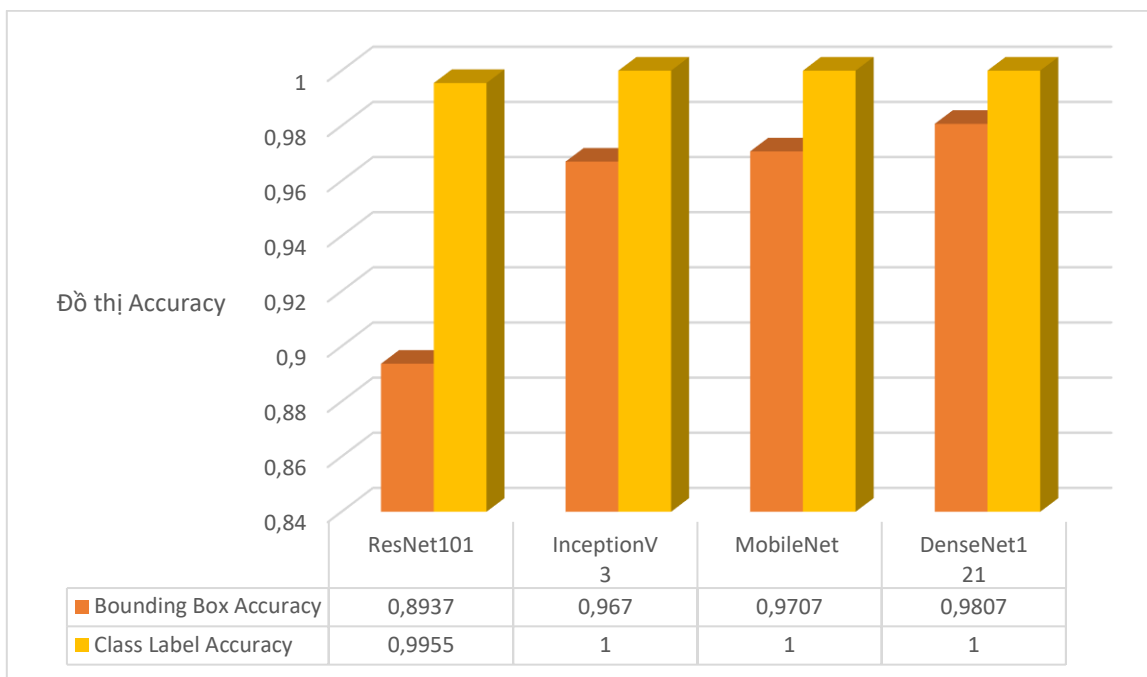
#### 4.3.5.3. Thời gian huấn luyện



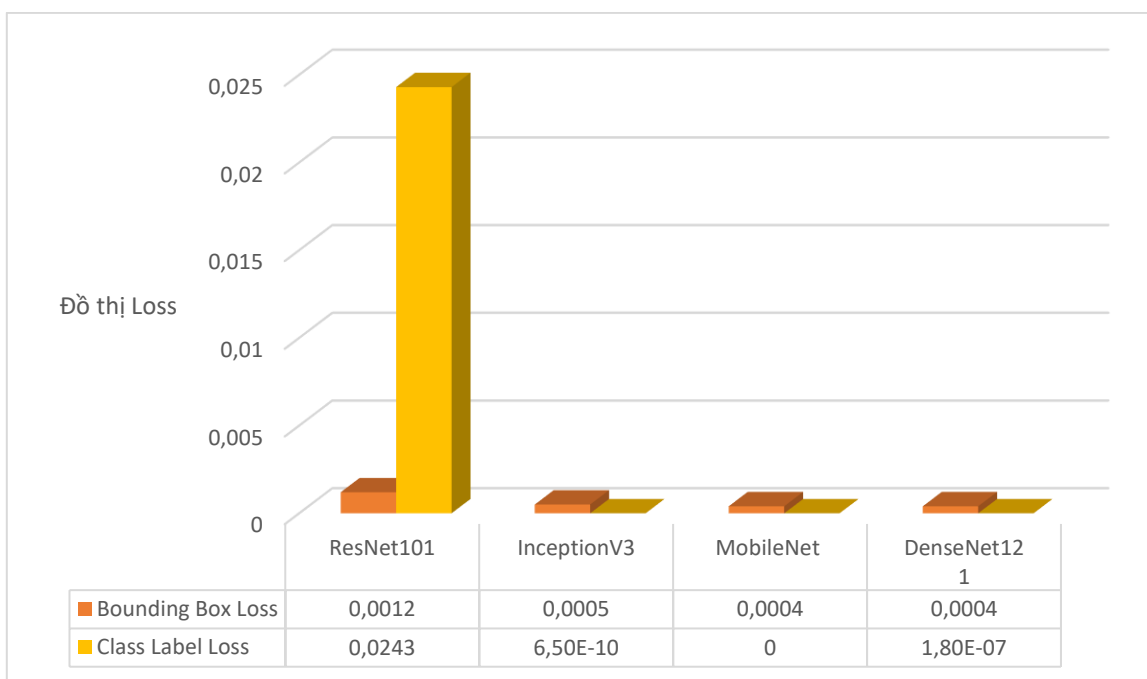
Hình 3.16. Biểu đồ so sánh thời gian huấn luyện của các kịch bản đề xuất

## 4.3.2. Kết quả thực nghiệm

### 4.3.2.1. Độ đo chính xác thực nghiệm




### 4.3.2.2. Độ đo Loss thực nghiệm




#### 4.3.2.3. Kết quả kiểm tra thực nghiệm

#### 4.3.2.4. Kết quả kiểm tra thực nghiệm trên mạng ResNet101



Hình 3.17. Ảnh minh họa cho kết quả phân loại với kịch bản 1

#### 4.3.2.5. Kết quả kiểm tra thực nghiệm trên mạng InceptionV3



Hình 3.18. Ảnh minh họa cho kết quả phân loại với kịch bản 2

#### 4.3.2.6. Kết quả kiểm tra thực nghiệm trên mạng MobileNet



Hình 3.19. Ảnh minh họa cho kết quả phân loại với kịch bản 3

#### 4.3.2.7. Kết quả kiểm tra thực nghiệm trên mạng DenseNet121



Hình 3. 20. Ảnh minh họa cho kết quả phân loại với kích bản 4

#### 4.4. Đánh giá

Bảng 4.1. Bảng tổng hợp kết quả so sánh đánh giá mô hình qua tập dữ liệu thực nghiệm

Kịch bản	Model	Dataset	Độ chính xác (Accuracy) (%)	Loss (%)	Thời gian đào tạo (phút)
1	ResNet101	Healthy brains Tumor dataset	97,72	0,50	64,52
2	InceptionV3		100,00	0,00317	37,54
3	MobileNet		100,00	0,00	20,43
4	DenseNet121		100,00	0,00812	39,55

Sau khi đánh giá các mô hình ResNet101, InceptionV3, MobileNet và DenseNet121 trong việc phát hiện và dự đoán bounding box cho khối u não từ ảnh chụp cộng hưởng từ của não trên tập dữ liệu kết hợp "Healthy brains" và "Tumor dataset", nhóm em có những nhận xét như sau:

Mô hình ResNet101 đạt được độ chính xác 97,72%, tỷ lệ loss là 0,50% và mất 64,52 phút để đào tạo. Dù độ chính xác không cao bằng các mô hình khác, ResNet101 vẫn là một lựa chọn đáng cân nhắc nếu ta cần một sự cân bằng giữa độ chính xác và thời gian đào tạo.

Các mô hình InceptionV3, MobileNet và DenseNet121 đều đạt được độ chính xác là 100%, tuy nhiên thời gian đào tạo và tỷ lệ loss giữa chúng có sự khác biệt.

InceptionV3 mất 37,54 phút để đào tạo với tỷ lệ loss là 0,00317%. Mô hình này có thể là lựa chọn tốt nếu không quá quan tâm đến thời gian đào tạo.

MobileNet mất ít thời gian đào tạo nhất là 20,43 phút và không có tỷ lệ loss. Điều này cho thấy MobileNet có hiệu suất tốt nhất trong số các mô hình được kiểm tra. Đây là lựa chọn hàng đầu nếu quan tâm đến thời gian đào tạo và tỷ lệ loss.

DenseNet121, mặc dù đạt được độ chính xác 100%, nhưng có tỷ lệ loss cao nhất là 0,00812% và thời gian đào tạo là 39,55 phút. Mô hình này có thể hữu ích nếu cần độ chính xác cao mà không quá quan tâm đến thời gian đào tạo.

Nhìn chung, tất cả các mô hình đều cho thấy khả năng đáng kể trong việc phát hiện khối u não từ ảnh chụp cộng hưởng từ của não. Trong số đó, MobileNet nổi bật với thời gian đào tạo nhanh nhất và không có tỷ lệ loss, đồng thời vẫn đạt được độ chính xác tối đa. Tuy nhiên, việc lựa chọn mô hình phù hợp nhất cần



# KẾT LUẬN HƯỚNG PHÁT TRIỂN

## 1. Kết luận

Mô hình ResNet101 có độ chính xác thấp hơn và thời gian đào tạo lâu hơn so với các mô hình khác.

Các mô hình InceptionV3, MobileNet và DenseNet121 đều đạt được độ chính xác 100%.

InceptionV3 có tỷ lệ loss cao hơn so với MobileNet, nhưng thấp hơn so với DenseNet121.

MobileNet có thời gian đào tạo thấp nhất và không có tỷ lệ loss, cho thấy hiệu suất tốt nhất trong số các mô hình được kiểm tra.

DenseNet121 có tỷ lệ loss cao nhất và thời gian đào tạo tương đối lâu.

## 2. Hướng phát triển

Đề tài có hướng phát triển trong tương lai như:

- Tiếp tục tìm hiểu và tinh chỉnh thêm các phương pháp và các tham số của mô hình để cải thiện hiệu suất, phát hiện các tổn thương có kích thước nhỏ và khó nhận thấy, tăng thêm độ chính xác cho mô hình.
- Xây dựng tập dữ liệu lớn hơn, với nhiều loại tổn thương hơn
- Sẽ tiếp tục nghiên cứu phương pháp để cải tiến thời gian huấn luyện cho mô hình.
- Tìm hiểu quy trình, phương pháp xây dựng và hiện thực ứng dụng để có thể sử dụng vào thực tế

## TÀI LIỆU THAM KHẢO

### Tiếng việt:

[1] Lê Thị Nguu Huỳnh, 2022, "Dò tìm và phân loại các tổn thương khu trú thường gặp ở gan trên ảnh CT dựa vào chỉ số Hounsfield và các kỹ thuật mạng học sâu", Trường Đại học Sư phạm Kỹ Thuật Vĩnh Long.

### Tiếng anh:

[2] He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770-778. 2016.

[3] Szegedy, Christian, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. "Rethinking the inception architecture for computer vision." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2818-2826. 2016.

[4] Howard, Andrew G., Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. "Mobilenets: Efficient convolutional neural networks for mobile vision applications." *arXiv preprint arXiv:1704.04861* (2017).

[5] Huang, Gao, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q. Weinberger. "Densely connected convolutional networks." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 4700-4708. 2017.

### Website

[7] [https://en.wikipedia.org/wiki/Deep\\_learning](https://en.wikipedia.org/wiki/Deep_learning) (truy cập lúc 2 giờ 22 phút ngày 15 tháng 6 năm 2023)

[8] <https://keras.io/api/applications/resnet/#resnet101-function> (truy cập lúc 7 giờ 34 phút ngày 8 tháng 6 năm 2023)

[9] <https://keras.io/api/applications/inceptionv3/> (truy cập lúc 9 giờ 30 phút ngày 8 tháng 6 năm 2023)

[10] <https://keras.io/api/applications/mobilenet/> (truy cập lúc 10 giờ 30 phút ngày 8 tháng 6 năm 2023)

[11] <https://keras.io/api/applications/densenet/#densenet121-function> (truy cập lúc 11 giờ 30 phút ngày 8 tháng 6 năm 2023)

[12] <https://en.wikipedia.org/wiki/Kaggle> (truy cập lúc 1 giờ 00 phút ngày 15 tháng 6 năm 2023)