


TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT VĨNH LONG
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO
MÔN: NGUYÊN LÝ MÁY HỌC

**ĐỀ TÀI: PHÂN LOẠI VÀ DỰ ĐOÁN
BOUNDING BOX CỦA KHỐI U NÃO
DỰA TRÊN ẢNH CHỤP CỘNG HƯỞNG TỪ**

Sinh viên thực hiện:

Lê Nguyễn Quang Bình 21022010

Nguyễn Hữu Thọ 21022008

Lớp: ĐH. KHMT 2021

Khóa: 2021 - 2025

Người hướng dẫn: TS. Phan Anh Cang

GV. Nguyễn Ngọc Hoàng Quyên

Vĩnh Long - Năm 2023

NHẬN XÉT & ĐÁNH GIÁ ĐIỂM CỦA NGƯỜI HƯỚNG DẪN

Ý thức thực hiện:

.....

.....

.....

Nội dung thực hiện:

.....

.....

.....

Hình thức trình bày:.....

.....

.....

.....

Tổng hợp kết quả:

.....

.....

.....

☐ Tổ chức báo cáo trước hội đồng

☐ Tổ chức chấm thuyết minh

Vĩnh Long, ngày tháng ... năm

Người hướng dẫn

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Chúng em, nhóm nghiên cứu, xin cam kết rằng nội dung trong bài báo cáo này là kết quả của quá trình nghiên cứu, tổng hợp và đánh giá cẩn thận và tỉ mỉ của chúng em. Chúng em đã tham khảo từ các nguồn tài liệu có nguồn gốc rõ ràng và đáng tin cậy, và chúng em đã chỉ sử dụng thông tin từ những nguồn đã được cho phép. Mọi nguồn được trích dẫn đều đã được ghi rõ ràng và đầy đủ trong bài báo cáo này.

Chúng em hiểu rằng việc cung cấp thông tin sai lệch có thể ảnh hưởng tới mục tiêu và tính xác thực của bài báo cáo này. Do đó, chúng em xin chịu trách nhiệm hoàn toàn nếu có bất kỳ thông tin sai lệch nào được phát hiện trong báo cáo của mình. Chúng em xin trân trọng cảm ơn và hy vọng bài báo cáo này sẽ đáp ứng được mọi yêu cầu và kỳ vọng.

Vĩnh Long, ngày 16 tháng 06 năm 2023

LỜI CẢM ƠN

Đầu tiên và quan trọng nhất, chúng em xin gửi lời cảm ơn chân thành đến Trường Đại học Sư Phạm Kỹ Thuật Vĩnh Long vì đã tích cực đưa môn Nguyên lý Máy học vào chương trình giảng dạy. Trên hết, chúng em muốn bày tỏ lòng biết ơn sâu sắc đến Giảng viên TS. Phan Anh Cang và GV. Nguyễn Ngọc Hoàng Quyên, người đã tận tâm hướng dẫn chúng em trong suốt quá trình học tập và hoàn thành báo cáo học phần Nguyên lý Máy học với đề tài đầy thách thức: “Phát hiện khối u não từ ảnh chụp cộng hưởng từ của não”.

Khi tham gia lớp Nguyên lý Máy học do thầy/cô phụ trách, chúng em đã học hỏi được nhiều kiến thức bổ ích, thúc đẩy tinh thần học tập hiệu quả và nghiêm túc. Những kiến thức này không những quý báu mà còn là hành trang vững chắc cho chúng em tiến bước trong tương lai. Trong quá trình thực hiện báo cáo, các thầy đã rất nhiệt tình góp ý, giúp chúng em nâng cao chất lượng bài viết, đồng thời truyền đạt thêm nhiều kiến thức có ích trong suốt quá trình học và hoàn thành học phần Nguyên lý Máy học.

Bộ môn Nguyên lý Máy học là một môn học cực kỳ thú vị, bổ ích và thực tế. Nó không chỉ đảm bảo cung cấp đầy đủ kiến thức mà còn liên kết chặt chẽ với nhu cầu thực tế của sinh viên. Tuy nhiên, do hạn chế về kiến thức và khả năng tiếp thu thực tế, nhóm em còn gặp nhiều khó khăn.

Dù nhóm em đã cố gắng hết sức, nhưng không thể tránh khỏi những thiếu sót và những phần chưa chính xác trong báo cáo. Vì vậy, nhóm em rất mong nhận được sự đóng góp ý kiến nhiệt tình từ thầy/cô và các bạn, giúp nhóm em hoàn thiện hơn và rút kinh nghiệm cho những học phần sau.

Nhóm em xin chân thành cảm ơn thầy/cô!

MỤC LỤC

LỜI CAM ĐOAN	I
LỜI CẢM ƠN	II
DANH MỤC BẢNG	VII
DANH MỤC HÌNH ẢNH ĐỒ THỊ	VIII
1. Lý do chọn đề tài.....	1
2. Mục đích nghiên cứu.....	1
3. Đối tượng nghiên cứu.....	1
4. Phạm vi nghiên cứu.....	1
5. Phương pháp nghiên cứu.....	1
6. Ý nghĩa khoa học và ý nghĩa thực tiễn của dự đoán khối u não.	2
6.1. Ý nghĩa khoa học.....	2
6.2. Ý nghĩa thực tiễn.....	2
CHƯƠNG 1: CƠ SỞ KHOA HỌC CỦA ĐỀ TÀI	3
1.1. Cơ sở lý luận của đề tài	3
1.2. Cơ sở thực tiễn	4
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	5
2.1. Tìm hiểu về bệnh ung thư phổi	5
2.1.1. Định nghĩa về bệnh khối u não.....	5
2.1.2. Nguyên nhân gây ra bệnh	5
2.1.3. Dấu hiệu bệnh ung thư phổi	6
2.1.4. Hậu quả khi bị bệnh ung thư phổi.....	7
2.2. Tổng quan về nguyên lý máy học.....	8
2.2.1. Nguyên lý máy học là gì?	8
2.2.2. Ứng dụng của nguyên lý máy học	8
2.3. Kỹ thuật deep learning.....	9
2.3.1. Khái niệm Deep learning	9
2.3.2. Ưu nhược điểm của kỹ thuật deep learning.....	9
2.3.3. Ứng dụng của deep learning.....	10
2.4. Tổng quan về ngôn ngữ python.....	10
2.5. Thư viện Tensorflow	11

2.6. Thư viện Keras.....	11
2.7. Mô hình ResNet101	12
2.8. InceptionV3	13
2.9. Mô hình MobileNet.....	14
2.10. Mô hình DenseNet121	15
2.11. Đánh giá mô hình phân loại và dự đoán.....	17
2.11.1. Đánh giá độ đo chính xác (Accuracy).....	17
2.11.2. Độ đo Mean Average Precision (mAP) và Average precision (AP)	18
2.11.3. Độ đo F1-Score:	19
2.1.1. Ma trận nhầm lẫn (Confusion Matrix).....	20
2.1.2. ROC Curve (Receiver Operating Characteristic)	20
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU	23
3.1. Đặc điểm dữ liệu	23
3.2. Mô hình nghiên cứu.....	24
3.3. Phương pháp nghiên cứu	24
3.3.1. Định nghĩa hàm mất mát (loss function)	24
3.3.2. Giai đoạn huấn luyện mô hình	26
3.3.3. Giai đoạn kiểm thử mô hình.....	26
3.4. Kịch bản thực nghiệm	27
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THỰC NGHIỆM	28
4.1. Mô trường cài đặt.....	28
4.2. Các tham số của mô hình.....	28
4.3.1. Tham số mô hình ResNet101	28
4.3.2. Tham số mô hình InceptionV3	29
4.3.3. Tham số mô hình MobileNet.....	29
4.3.4. Tham số mô hình DenseNet121	29
4.3.5. Kết quả nghiên cứu huấn luyện	29
4.3.5.1. Kịch bản 1 (ResNet101)	29
4.3.5.2. Kịch bản 2 (InceptionV3).....	30
4.3.5.3. Kịch bản 3 (MobileNet).....	31
4.3.5.4. Kịch bản 4 (DenseNet121)	32

4.3. Kết quả.....	33
4.3.1. Kết quả nghiên cứu huấn luyện.....	33
4.3.5.1. Độ đo chính xác huấn luyện	33
4.3.5.2. Độ đo Loss huấn luyện	34
4.3.5.3. Đo Precision huấn luyện.....	35
4.3.5.4. Đo Recall huấn luyện	35
4.3.5.5. Đo F1-score huấn luyện.....	36
4.3.5.6. Thời gian huấn luyện.....	36
4.3.2. Kết quả thực nghiệm	37
4.3.2.1. Độ đo chính xác thực nghiệm.....	37
4.3.2.2. Độ đo Loss thực nghiệm.....	37
4.3.2.3. Kết quả kiểm tra thực nghiệm trên mạng ResNet101	38
4.3.2.4. Kết quả kiểm tra thực nghiệm trên mạng InceptionV3	38
4.3.2.5. Kết quả kiểm tra thực nghiệm trên mạng MobileNet.....	38
4.3.2.6. Kết quả kiểm tra thực nghiệm trên mạng DenseNet121	39
4.4. Đánh giá.....	39
KẾT LUẬN HƯỚNG PHÁT TRIỂN	41
1. Kết luận	41
2. Hướng phát triển	41

DANH MỤC CÁC CHỮ VIẾT TẮT

STT	Ký hiệu	Nội dung đầy đủ
1	AI	Artificial Intelligent
2	CPU	Central Processing Unit
3	CNN	Convolutional Neural Networks
4	GPU	Graphics Processing Unit

DANH MỤC BẢNG

Bảng 3.1. Các kịch bản đề xuất và các tham số huấn luyện.....	27
Bảng 4.1. Bảng tổng hợp kết quả so sánh đánh giá mô hình qua tập dữ liệu thực nghiệm	39

DANH MỤC HÌNH ẢNH ĐỒ THỊ

Hình 1.1. Khối u não	3
Hình 2.1. Cấu trúc cơ bản của khối u não	5
Hình 2.2. Hình sơ bộ Deep learning	9
Hình 2.3. Mô hình mạng ResNet.....	12
Hình 2.4. Mô hình mạng InceptionV3.....	13
Hình 2.5. Mô hình mạng MobileNet	14
Hình 2.6. Mô hình mạng DenseNet.....	15
Hình 2.7. Minh họa phân loại.....	17
Hình 2.8. Precision và Recall	18
Hình 2. 9. Minh họa công thức Precision và Recall.....	19
Hình 2.10. Ví dụ về ma trận nhầm lẫn.	20
Hình 2. 11. Sự thay đổi của TPR và FPR.....	21
Hình 3.1. Tập dữ liệu huấn luyện và kiểm thử phân loại khối u não	23
Hình 3.2. Mô hình nghiên cứu.....	24
Hình 4.1. Biểu đồ accuracy và loss của kịch bản 1	29
Hình 4.2. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 1	30
Hình 4.3. Biểu đồ Ma trận nhầm lẫn kịch bản 1	30
Hình 4.4. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 1	30
Hình 4.5. Biểu đồ accuracy và loss của kịch bản 2	30
Hình 4.6. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 2	31
Hình 4.7. Biểu đồ Ma trận nhầm lẫn kịch bản 2	31
Hình 4.8. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 2	31
Hình 4.9. Biểu đồ accuracy và loss của kịch bản 3	31
Hình 4.10. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 3.....	32
Hình 4.11. Biểu đồ Ma trận nhầm lẫn kịch bản 3	32
Hình 4.12. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 3	32
Hình 4.13. Biểu đồ accuracy và loss của kịch bản 4	32
Hình 4.14. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 4	33

Hình 4.15. Biểu đồ Ma trận nhầm lẫn kịch bản 4	33
Hình 4.16. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 4	33
Hình 4.17. Biểu đồ so sánh độ accuracy của các kịch bản đề xuất	34
Hình 4.18. Biểu đồ so sánh độ loss của các kịch bản đề xuất	34
Hình 4.19. Biểu đồ so sánh độ Precision của các kịch bản đề xuất	35
Hình 4.20. Biểu đồ so sánh độ Recall của các kịch bản đề xuất	35
Hình 4.21. Biểu đồ so sánh độ F1-score của các kịch bản đề xuất	36
Hình 4.22. Biểu đồ so sánh thời gian huấn luyện của các kịch bản đề xuất	36
Hình 4.23. Biểu đồ so sánh độ chính xác thực nghiệm của các kịch bản đề xuất.....	37
Hình 4.24. Biểu đồ so sánh độ mất mát thực nghiệm của các kịch bản đề xuất	37
Hình 4.25. Ảnh minh họa cho kết quả phân loại với kịch bản 1	38
Hình 4.26. Ảnh minh họa cho kết quả phân loại với kịch bản 2	38
Hình 4.27. Ảnh minh họa cho kết quả phân loại với kịch bản 3	38
Hình 4.28. Ảnh minh họa cho kết quả phân loại với kịch bản 4	39

MỞ ĐẦU

1. Lý do chọn đề tài.

Khối u não là sự phát triển bất thường của các tế bào trong não. Các khối u não có thể lành tính (không ung thư) hoặc ác tính (ung thư). Các khối u não lành tính không lan sang các bộ phận khác của cơ thể, nhưng chúng vẫn có thể gây ra vấn đề bằng cách chèn ép hoặc xâm lấn mô não bình thường. Các khối u não ác tính có thể lan sang các bộ phận khác của cơ thể và chúng thường gây tử vong. Vì vậy việc nghiên cứu máy học nhằm nhận diện khối u trong y học nhằm tiết kiệm nhân lực là điều vô cùng cần thiết.

2. Mục đích nghiên cứu.

Đề tài gồm các mục đích như sau:

- Giảm thời gian chuẩn đoán và tăng độ chính xác từ đó có thể đưa ra các quyết định điều trị tốt hơn dựa và kỹ thuật máy học.
- Khoanh vùng, chuẩn đoán kích thước cũng như hình dạng của khối u và để xác định chúng có lây lan sang các phần khác của não hay không.
- Đánh giá nguy cơ tái phát ung thư từ đó có thể lựa chọn cách điều trị tốt nhất.

3. Đối tượng nghiên cứu.

Trong nghiên cứu này, đối tượng chính là bộ dữ liệu ảnh chụp cộng hưởng từ của não, bao gồm cả ảnh của não bình thường và não có khối u.

4. Phạm vi nghiên cứu.

Trong nghiên cứu này, phạm vi nghiên cứu rất rộng lớn, bao gồm việc thu thập, xử lý và phân tích dữ liệu ảnh chụp cộng hưởng từ (MRI) của não. Phạm vi này cũng bao gồm việc thiết kế, huấn luyện, đánh giá và tối ưu hóa các mô hình máy học để phát hiện và phân loại khối u.

5. Phương pháp nghiên cứu.

5.1. Phương pháp nghiên cứu lý thuyết.

Học sâu là một loại máy học sử dụng mạng thần kinh nhân tạo để học từ dữ liệu. Các thuật toán học sâu đã được chứng minh là rất hiệu quả trong việc phân loại hình ảnh khối u não và chúng đang được sử dụng trong một số thử nghiệm lâm sàng.

5.2. Phương pháp nghiên cứu thực nghiệm.

Dự đoán chéo tập dữ liệu được chia ngẫu nhiên thành tập huấn luyện và tập kiểm tra. Tập huấn luyện được sử dụng để huấn luyện thuật toán học máy và tập kiểm tra được sử dụng để đánh giá hiệu suất của thuật toán.

6. Ý nghĩa khoa học và ý nghĩa thực tiễn của dự đoán khối u não.

6.1. Ý nghĩa khoa học.

Việc phát hiện và chẩn đoán sớm các khối u não trong máy học, có khả năng cải thiện độ chính xác và hiệu quả của việc phát hiện khối u não, đồng thời giúp các bác sĩ đưa ra quyết định điều trị tốt hơn. Còn có thể được sử dụng để phân đoạn các khối u trong hình ảnh y tế giúp đo kích thước và hình dạng của khối u, đồng thời xác định xem chúng có lan sang các phần khác của não hay không. Ngoài ra có thể được sử dụng để dự đoán nguy cơ tái phát khối u cũng như có thể đưa ra các so sánh về phương pháp điều trị khác nhau

6.2. Ý nghĩa thực tiễn.

Giúp đưa ra dự đoán chính xác hơn so với con người, giảm thời gian phân tích ảnh từ đó giảm thời gian chuẩn đoán và điều trị. Việc phát hiện và chẩn đoán sớm các khối u não có thể giúp cải thiện kết quả của bệnh nhân, chẳng hạn như tăng tỷ lệ sống sót và giảm tác dụng phụ do điều trị. Còn có thể tự động hóa từ đó giảm được các chi phí chuẩn đoán.

7. Cấu trúc đề cương

Chương 1: Tổng quan đề tài

Chương 2: Cơ sở khoa học của đề tài

Chương 3: Cơ sở lý thuyết

Chương 4: Phương pháp đề xuất

Chương 5: Kết quả nghiên cứu và thực nghiệm


Chương 6: Kết luận

CHƯƠNG 1: CƠ SỞ KHOA HỌC CỦA ĐỀ TÀI

1.1. Cơ sở lý luận của đề tài

Cơ sở lý luận của đề dựa trên sự kết hợp giữa lĩnh vực y học hình ảnh, đặc biệt là ảnh chụp cộng hưởng từ, và lĩnh vực học máy, cụ thể là thị giác máy tính và học sâu.

Từ phía y học, ảnh chụp cộng hưởng từ đã được sử dụng rộng rãi để chụp hình ảnh chi tiết của cấu trúc trong não, bao gồm các khối u. Sử dụng các kỹ thuật tiên tiến, các bác sĩ có thể nhìn thấy các khối u, nhưng việc phân tích và xác định chính xác vị trí và kích thước của khối u đòi hỏi thời gian và kỹ năng chuyên môn cao.



Hình 1.1. Khối u não

Đó là nơi mà học máy, thị giác máy tính, và học sâu có thể đóng góp. Nhờ vào sự phát triển của các mô hình học sâu như CNN (Convolutional Neural Networks), R-CNN (Region-based Convolutional Neural Networks) hay YOLO (You Only Look Once), chúng ta có thể huấn luyện các mô hình để tự động nhận biết và vẽ bounding box xung quanh các khối u trên ảnh chụp cộng hưởng từ. Điều này không chỉ tiết kiệm thời gian cho các bác sĩ mà còn giúp tăng chất lượng và độ chính xác của việc phân loại và định vị khối u.

Vì vậy, cơ sở lý luận của đề tài này dựa trên việc kết hợp sự hiểu biết sâu sắc về y học hình ảnh và công nghệ học máy, tạo ra một giải pháp tiên tiến cho việc phân tích và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ.

1.2. Cơ sở thực tiễn

Cơ sở thực tiễn của đề tài rất rõ ràng và thiết thực, đặc biệt khi xét trong bối cảnh y học hiện đại và ngày càng phụ thuộc vào công nghệ.

Trong y học hình ảnh, việc xác định chính xác vị trí và kích thước của khối u não là yếu tố quan trọng đối với việc đưa ra chẩn đoán chính xác và lựa chọn phương pháp điều trị phù hợp. Hiện nay, việc này thường đòi hỏi sự can thiệp của các chuyên gia y học hình ảnh, nhưng quy trình này có thể mất thời gian và năng lực nhân sự.


Sự xuất hiện của các mô hình học máy trong việc dự đoán bounding box của khối u não từ ảnh chụp cộng hưởng từ có thể tạo ra sự thay đổi lớn trong ngành. Nhờ vào công nghệ này, chúng ta có thể tự động hóa phần lớn quy trình, giảm bớt gánh nặng cho các chuyên gia và tăng tốc độ và độ chính xác của việc chẩn đoán.

Đây không chỉ là một bước tiến lớn trong việc cung cấp chăm sóc sức khỏe chất lượng cao và kịp thời cho bệnh nhân, mà còn mở ra cánh cửa cho việc áp dụng công nghệ học máy vào nhiều lĩnh vực khác trong y học, từ việc phát hiện bệnh tật sớm cho đến việc tối ưu hóa quy trình điều trị. Đề tài này, do đó, không chỉ đáng giá vì mục tiêu nghiên cứu của nó, mà còn vì những tầm nhìn lớn hơn mà nó mang lại cho cộng đồng y học và công nghệ.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tìm hiểu về bệnh ung thư phổi

2.1.1. Định nghĩa về bệnh khối u não



Hình 2.1. Cấu trúc cơ bản của khối u não

Một khối u não (còn được gọi là khối u nội sọ) là một khối mô bất thường trong đó các tế bào phát triển và nhân lên không kiểm soát, dường như không được kiểm soát bởi các cơ chế kiểm soát các tế bào bình thường. Các khối u có thể lành tính (không phải ung thư) hoặc ác tính (ung thư).

2.1.2. Nguyên nhân gây ra bệnh

- Tuổi tác: Nguy cơ phát triển khối u não tăng theo tuổi tác. Độ tuổi chẩn đoán trung bình là 65 tuổi. Tuy nhiên, u não có thể xảy ra ở mọi lứa tuổi, kể cả ở trẻ em.
- Giới tính: Đàn ông có khả năng phát triển khối u não cao hơn một chút so với phụ nữ.
- chủng tộc: U não phổ biến ở người da trắng hơn người da đen.
- Tiền sử gia đình: Những người có tiền sử gia đình mắc bệnh u não có nguy cơ mắc bệnh u não cao hơn.

- Tiếp xúc với bức xạ: Tiếp xúc với mức độ cao của bức xạ, chẳng hạn như từ liệu pháp bức xạ ion hóa, có thể làm tăng nguy cơ phát triển khối u não. Đây là một rủi ro hiếm gặp, nhưng điều quan trọng cần lưu ý là nó có tồn tại.
- Một số yếu tố môi trường: Tiếp xúc với một số yếu tố môi trường, chẳng hạn như một số hóa chất hoặc vi rút, cũng có thể làm tăng nguy cơ phát triển khối u não. Những yếu tố này không được hiểu rõ, nhưng chúng được cho là có vai trò trong một số ít trường hợp.

2.1.3. Dấu hiệu bệnh ung thư phổi

- Nhức đầu: Nhức đầu là triệu chứng phổ biến nhất của khối u não. Chúng có thể tồi tệ hơn vào buổi sáng hoặc khi gắng sức. Những cơn đau đầu có thể khác với bất kỳ cơn đau đầu nào bạn từng mắc phải trước đây. Chúng có thể nghiêm trọng hơn, thường xuyên hơn hoặc kéo dài hơn.
- Buồn nôn và nôn: Buồn nôn và nôn có thể do tăng áp lực bên trong hộp sọ. Áp lực này có thể do chính khối u gây ra hoặc do sự phát triển của khối u.
- Co giật: Co giật có thể do khối u đè lên bề mặt não hoặc làm gián đoạn hoạt động điện trong não. Động kinh có thể ngắn hoặc kéo dài. Chúng có thể nhẹ hoặc nặng.
- Các vấn đề về thị lực: Các vấn đề về thị lực có thể do khối u đè lên dây thần kinh thị giác hoặc làm gián đoạn khả năng xử lý thông tin thị giác của não. Các vấn đề về thị lực có thể bao gồm nhìn mờ, nhìn đôi hoặc mất thị lực.
- Các vấn đề về thính giác: Các vấn đề về thính giác có thể do khối u đè lên dây thần kinh thính giác hoặc làm gián đoạn khả năng xử lý thông tin thính giác của não. Các vấn đề về thính giác có thể bao gồm mất thính giác, ù tai hoặc khó hiểu lời nói.
- Thay đổi tính cách: Thay đổi tính cách có thể do khối u đè lên thùy trán của não, nơi chịu trách nhiệm về tính cách và hành vi. Thay đổi tính cách có thể bao gồm thay đổi tâm trạng, cấu kình và thay đổi hành vi xã hội.
- Các vấn đề về trí nhớ: Các vấn đề về trí nhớ có thể do khối u đè lên thùy thái dương của não, chịu trách nhiệm về trí nhớ. Các vấn đề về trí nhớ có thể bao gồm khó nhớ các sự kiện gần đây, khó nhớ tên và khó học thông tin mới.

- Yếu hoặc liệt: Yếu hoặc liệt một bên cơ thể có thể do khối u đè lên vỏ não vận động. Điểm yếu hoặc tê liệt có thể từ nhẹ đến nặng.
- Chóng mặt hoặc các vấn đề về thăng bằng: Chóng mặt hoặc các vấn đề về thăng bằng có thể do các khối u đè lên hệ thống tiền đình của não, hệ thống chịu trách nhiệm về sự cân bằng. Chóng mặt hoặc các vấn đề về thăng bằng có thể khiến bạn khó đi lại, đứng hoặc ngồi thẳng.
- Các vấn đề về giọng nói: Các vấn đề về giọng nói có thể do khối u chèn ép lên các trung tâm nói của não. Các vấn đề về lời nói có thể bao gồm khó nói rõ ràng, khó hiểu lời nói và khó nuốt.
- Mệt mỏi: Mệt mỏi là triệu chứng phổ biến của u não. Nó có thể được gây ra bởi chính khối u hoặc do điều trị khối u. Mệt mỏi có thể gây khó khăn cho các hoạt động hàng ngày.

2.1.4. Hậu quả khi bị bệnh ung thư phổi

- Tử vong: Nguy cơ tử vong do u não phụ thuộc vào loại khối u, kích thước khối u, tuổi và sức khỏe tổng thể của bệnh nhân. Ví dụ, nguy cơ tử vong do u nguyên bào thần kinh đệm, một loại u thần kinh đệm cao cấp, là khoảng 50% trong vòng 5 năm sau khi chẩn đoán. Tuy nhiên, nguy cơ tử vong do u màng não, một loại u thần kinh đệm cấp thấp, thấp hơn nhiều, khoảng 5% trong vòng 10 năm sau khi chẩn đoán.
- Tàn tật: Nguy cơ tàn tật do khối u não phụ thuộc vào vị trí của khối u, kích thước của khối u và loại khối u. Ví dụ, các khối u phát triển gần vỏ não vận động có thể gây tê liệt, trong khi các khối u phát triển gần trung tâm ngôn ngữ của não có thể gây ra các vấn đề về giọng nói.
- Tác dụng phụ của điều trị: Các tác dụng phụ của điều trị u não phụ thuộc vào loại điều trị được sử dụng. Ví dụ, phẫu thuật có thể gây đau, sưng và nhiễm trùng. Xạ trị có thể gây rụng tóc, mệt mỏi, buồn nôn và nôn. Hóa trị có thể gây rụng tóc, mệt mỏi, buồn nôn, nôn và suy giảm hệ miễn dịch.
- Khó khăn về tài chính: Chi phí điều trị u não có thể cao, đặc biệt nếu khối u lớn hoặc nếu bệnh nhân cần nhiều loại điều trị. Chi phí điều trị cũng có thể phụ thuộc vào bảo hiểm

của bệnh nhân. Ví dụ, bệnh nhân có bảo hiểm tư nhân có thể phải trả một phần chi phí điều trị, trong khi bệnh nhân có Medicare hoặc Medicaid có thể không phải trả bất kỳ khoản nào.

2.2. Tổng quan về nguyên lý máy học

2.2.1. Nguyên lý máy học là gì?

Máy học (Machine Learning) là một nhánh của trí tuệ nhân tạo (Artificial Intelligence), tập trung vào việc xây dựng các mô hình và thuật toán cho phép máy tính "học" từ dữ liệu, thay vì được lập trình cụ thể để thực hiện một tác vụ nhất định. Mục tiêu chính của máy học là tạo ra mô hình dự đoán hoặc quyết định mà không cần sự can thiệp hay chỉ đạo rõ ràng từ con người.

2.2.2. Ứng dụng của nguyên lý máy học

Một số ứng dụng của nguyên lý máy học như:

Phân loại hình ảnh: Máy học được sử dụng để xây dựng mô hình có thể phân loại hình ảnh vào các loại khác nhau dựa trên nội dung của chúng. Ví dụ, các mô hình phân loại hình ảnh có thể được sử dụng để nhận dạng các đối tượng trong hình ảnh, nhận dạng khuôn mặt hoặc phát hiện các đối tượng cụ thể.

Phân tích ngôn ngữ tự nhiên (NLP): Máy học cũng được sử dụng trong việc phân tích và xử lý ngôn ngữ tự nhiên. Ví dụ, các mô hình máy học có thể được sử dụng để dịch ngôn ngữ, phân loại văn bản, phát hiện cảm xúc từ văn bản, hoặc tạo ra văn bản mới.

Dự đoán thị trường tài chính: Trong thị trường tài chính, máy học được sử dụng để xây dựng mô hình dự đoán giá cổ phiếu, dự đoán xu hướng thị trường hoặc phân tích rủi ro tài chính.

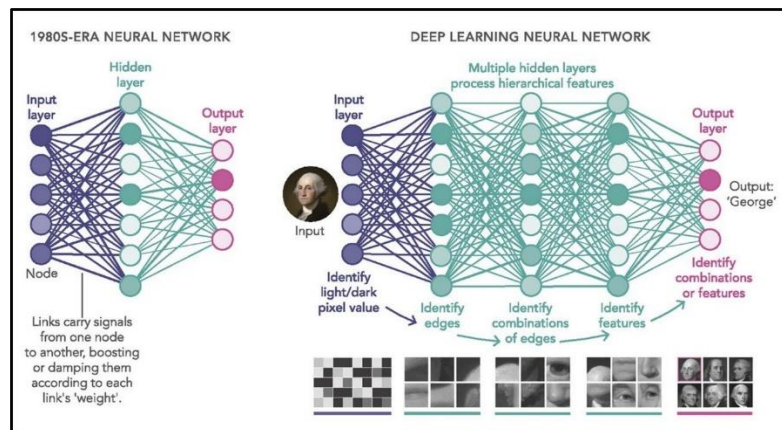
Y tế: Trong ngành y tế, máy học có thể được sử dụng để dự đoán bệnh dựa trên các triệu chứng, hình ảnh y tế, hoặc dữ liệu về lịch sử bệnh của bệnh nhân.

Tự động hóa quảng cáo: Trong quảng cáo, máy học có thể được sử dụng để tự động hóa việc nhắm mục tiêu quảng cáo dựa trên dữ liệu về hành vi của người dùng.

Dự đoán khách hàng: Máy học có thể được sử dụng để phân loại khách hàng, dự đoán hành vi mua hàng và tối ưu hóa chiến lược tiếp thị.

2.3. Kỹ thuật deep learning

2.3.1. Khái niệm Deep learning



Hình 2.2. Hình sơ bộ Deep learning

Deep learning là một lớp của học máy dựa trên mạng nơ-ron nhân tạo, sử dụng nhiều lớp để trích xuất đặc trưng cấp cao từ đầu vào thô. Thuật ngữ "deep" trong "deep learning" chỉ số lớp mà qua đó dữ liệu được biến đổi. Các hệ thống học sâu tự động học cách biến đổi dữ liệu đầu vào thành biểu diễn phức tạp và trừu tượng hơn ở mỗi lớp. Học sâu có thể được áp dụng trong các tác vụ học giám sát và không giám sát, và đã được sử dụng thành công trong nhiều lĩnh vực khác nhau, từ xử lý hình ảnh và nhận dạng giọng nói đến dịch máy và phân tích hình ảnh y tế

2.3.2. Ưu nhược điểm của kỹ thuật deep learning

Ưu điểm của Deep Learning bao gồm:

- Hệ thống có khả năng tự động hóa việc học từ dữ liệu, giúp giảm thiểu quá trình tạo đặc trưng thủ công.
- Deep learning cho phép tạo ra các mô hình phức tạp với độ chính xác cao, nhờ sử dụng nhiều lớp trong mạng neuron.
- Khả năng xử lý các bài toán phức tạp, như nhận dạng hình ảnh, giọng nói, và xử lý ngôn ngữ tự nhiên.
- Khả năng tiếp nhận và học từ lượng dữ liệu lớn, giúp tối ưu hóa hiệu quả trong việc học.

- Khả năng học một cách tự động từ dữ liệu, điều này là một lựa chọn tốt so với học máy truyền thống dựa trên chuyên môn của con người.

- Deep learning cho phép xem xét thế giới dưới dạng cấu trúc không giám sát.

Tuy nhiên, Deep Learning cũng có một số nhược điểm như:

- Deep Learning thường khó so sánh với các phương pháp tạo ra thủ công.
- Rất khó để đánh giá hiệu suất của nó trong các ứng dụng thực tế; các ứng dụng có thể khác biệt lớn từ ứng dụng này sang ứng dụng khác.

- Cần một lượng dữ liệu lớn để huấn luyện, điều này đôi khi không phù hợp với các tình huống mà dữ liệu có sẵn là hạn chế.

- Tốc độ học tương đối chậm so với các phương pháp học máy khác.

- Cần nhiều tài nguyên tính toán và bộ nhớ, đặc biệt là khi huấn luyện với các mô hình lớn và dữ liệu lớn.

- Yêu cầu sử dụng các kỹ thuật tối ưu hóa tiên tiến, và những kỹ thuật này cần phải được tích hợp để có được kết quả tốt

2.3.3. Ứng dụng của deep learning

Một số ứng dụng của deep learning như:

- Trong y tế: Học sâu được sử dụng trong phân loại hình ảnh y tế, phân tích gen, dự đoán bệnh, và nhiều ứng dụng khác trong y học.

- Trong ngành công nghiệp ô tô: Các công ty như Tesla đang sử dụng học sâu để phát triển xe tự lái. Học sâu giúp các hệ thống nhận dạng đối tượng, dẫn đường và tránh va chạm.

- Trong giáo dục: Học sâu cũng được sử dụng để phát triển các hệ thống giáo dục cá nhân hóa và cải thiện kết quả học tập

2.4. Tổng quan về ngôn ngữ python

Python là ngôn ngữ lập trình máy tính bậc cao thường được sử dụng để xây dựng trang web và phần mềm, tự động hóa các tác vụ và tiến hành phân tích dữ liệu. Python là

ngôn ngữ có mục đích chung, nghĩa là nó có thể được sử dụng để tạo nhiều chương trình khác nhau và không chuyên biệt cho bất kỳ vấn đề cụ thể nào.

2.5. Thư viện Tensorflow

TensorFlow là một thư viện phần mềm nguồn mở và miễn phí dành cho máy học và trí tuệ nhân tạo. Nó có thể được sử dụng trong nhiều nhiệm vụ nhưng tập trung đặc biệt vào đào tạo và suy luận về mạng lưới thần kinh sâu.

2.6. Thư viện Keras


Keras là một thư viện học sâu mã nguồn mở trong Python được phát triển nhằm tạo ra một cách tiếp cận dễ dàng và thuận tiện để xây dựng và huấn luyện các mô hình học sâu. Nó cung cấp một giao diện trực quan và dễ sử dụng, tập trung vào việc tối ưu hóa trải nghiệm người dùng và giúp họ nhanh chóng triển khai các mô hình học sâu.

Keras hỗ trợ nhiều kiến trúc mạng nơ-ron khác nhau, bao gồm cả các mạng nơ-ron truyền thẳng (feed-forward), mạng nơ-ron hồi quy (recurrent neural networks - RNNs), và mạng nơ-ron tích chập (convolutional neural networks - CNNs). Thư viện này cung cấp các công cụ để làm việc với dữ liệu, định nghĩa và huấn luyện mô hình, và cuối cùng là đánh giá và tối ưu hóa mô hình.

Một điểm mạnh của Keras là khả năng tương thích với các thư viện học sâu phổ biến khác như TensorFlow, Theano, hoặc CNTK, giúp người dùng có thể dễ dàng di chuyển giữa các thư viện này mà không cần phải thay đổi code đáng kể. Điều này giúp Keras trở thành lựa chọn hàng đầu cho nhiều nhà khoa học dữ liệu và nhà nghiên cứu học máy.

Cuối cùng, Keras cung cấp một lượng lớn tài liệu hướng dẫn và ví dụ, giúp cho việc học và sử dụng thư viện này trở nên dễ dàng hơn, ngay cả với những người mới học lập trình.

2.7. Mô hình ResNet101



Hình 2.3. Mô hình mạng ResNet

ResNet, hay còn gọi là Residual Network, là một mạng nơ-ron sâu được giới thiệu bởi Kaiming He và đồng nghiệp tại Microsoft Research vào năm 2015. ResNet đã mang lại cải tiến đột phá trong việc giảm thiểu vấn đề biến mất gradient (vanishing gradient) khi đào tạo các mạng nơ-ron sâu.

ResNet101 là một biến thể của ResNet có 101 lớp, bao gồm 33 mô-đun lặp lại (repeated blocks) với 3 lớp mỗi mô-đun (đây là lý do vì sao có tên là '101').

Kiến trúc mạng: ResNet101 bao gồm nhiều khối lặp lại, mỗi khối gồm 3 lớp: lớp tích chập 1x1 (convolutional layer), lớp tích chập 3x3, và một lớp tích chập 1x1 nữa. Các lớp 1x1 được sử dụng để giảm và tăng số lượng kênh, trong khi lớp 3x3 thực hiện trích xuất đặc trưng.

Các khối dư (Residual Blocks): Những khối này là trái tim của ResNet. Mỗi khối dư bao gồm một "đường dư" (shortcut connection) hoặc "đường tắt" (skip connection), cho phép gradient được truyền thẳng qua các lớp. Điều này giúp giảm bớt vấn đề biến mất gradient bằng cách giữ cho gradient ổn định trong suốt quá trình lan truyền ngược (backpropagation).

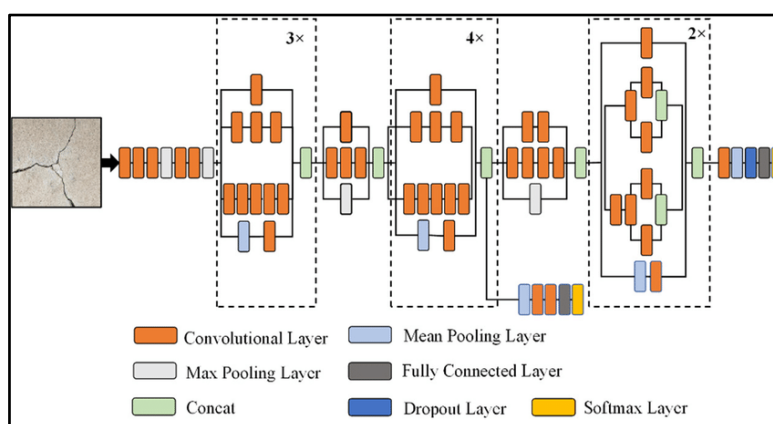
Hàm Kích hoạt và Chuẩn hóa theo Batch: Sau mỗi lớp tích chập, ResNet sử dụng hàm kích hoạt ReLU và chuẩn hóa theo batch (batch normalization). Chuẩn hóa theo batch giúp mô hình hội tụ nhanh hơn và giảm thiểu overfitting, còn ReLU giúp giảm bớt vấn đề biến mất gradient.

Global Average Pooling và Lớp Kết nối Đầy đủ (Fully Connected Layer): Cuối cùng, ResNet sử dụng lớp Global Average Pooling để giảm số lượng tham số, sau đó đi qua một lớp kết nối đầy đủ để phân loại.

Mất mát và Tối ưu hóa: ResNet sử dụng hàm mất mát softmax cho việc phân loại và một thuật toán tối ưu hóa như SGD hoặc Adam để đào tạo mạng.

ResNet101, như các biến thể khác của ResNet, thể hiện khả năng mạnh mẽ trong việc giải quyết các vấn đề phức tạp, như việc nhận dạng hình ảnh, và đạt được kết quả hàng đầu trên nhiều bộ dữ liệu benchmark, bao gồm ImageNet.

2.8. InceptionV3



Hình 2.4. Mô hình mạng InceptionV3

InceptionV3 là phiên bản thứ ba của mạng Inception, được giới thiệu bởi Google trong bài viết "Rethinking the Inception Architecture for Computer Vision". Nó được thiết kế với mục đích tạo ra một mạng nơ-ron sâu có thể xử lý hình ảnh ở nhiều tỷ lệ kích thước khác nhau, và cải tiến hiệu suất đồng thời giảm số lượng tham số.

Kiến trúc mạng: InceptionV3 sử dụng nhiều khối Inception, mỗi khối gồm nhiều nhánh tích chập (convolutional) chạy song song và kết quả cuối cùng được nối lại. Nhờ cấu trúc này, InceptionV3 có thể học được nhiều đặc trưng ở nhiều mức độ độ phân giải khác nhau.

Khối Inception: Khối Inception bao gồm nhiều nhánh, mỗi nhánh bao gồm một chuỗi các lớp tích chập, tối thiểu là một lớp tích chập 1x1, tiếp theo có thể là một lớp tích chập 3x3 hoặc 5x5. Ngoài ra, một nhánh riêng có thể chứa một lớp pooling. Mỗi lớp tích chập 1x1 trong một nhánh giúp giảm số lượng kênh, giảm số lượng tham số và tăng tốc độ tính toán.

Factorized Convolutions: InceptionV3 giới thiệu khái niệm về Factorized Convolutions, nơi mà một lớp tích chập 5×5 có thể được thay thế bằng hai lớp tích chập 3×3 liên tiếp. Điều này giúp giảm số lượng tham số mà không làm mất mát thông tin đặc trưng.

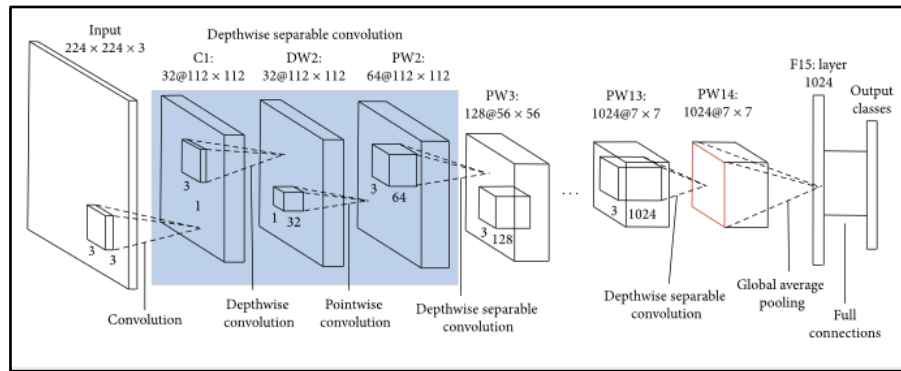
Auxiliary Classifiers: InceptionV3 cũng giới thiệu "Auxiliary Classifiers" để giúp giảm hiện tượng "vanishing gradient". Những Auxiliary Classifiers này là các lớp phân loại thêm vào giữa mạng, cung cấp thêm gradient cho quá trình lan truyền ngược (backpropagation).

Global Average Pooling và Softmax: Tại cuối mạng, InceptionV3 sử dụng lớp Global Average Pooling để giảm số lượng tham số, sau đó đi qua một lớp softmax để phân loại.

Mất mát và Tối ưu hóa: InceptionV3 sử dụng hàm mất mát softmax cho việc phân loại và một thuật toán tối ưu hóa như SGD hoặc Adam để đào tạo mạng.

Tóm lại, InceptionV3 là một mạng nơ-ron sâu hiệu quả và mạnh mẽ, có khả năng xử lý các vấn đề phức tạp liên quan đến hình ảnh và đạt được kết quả hàng đầu trên nhiều bộ dữ liệu benchmark, bao gồm ImageNet.

2.9. Mô hình MobileNet



Hình 2.5. Mô hình mạng MobileNet

MobileNet là một mạng nơ-ron sâu được giới thiệu bởi Google, được thiết kế đặc biệt để hoạt động trên các thiết bị có tài nguyên hạn chế như điện thoại di động hoặc các thiết bị nhúng. Nó sử dụng các kỹ thuật tiết kiệm tài nguyên để giảm số lượng tham số và tăng tốc độ tính toán, nhưng vẫn giữ được hiệu suất tương đối cao.

Depthwise Separable Convolution: Trái tim của MobileNet là kỹ thuật gọi là Depthwise Separable Convolution. Thay vì sử dụng lớp tích chập truyền thống, MobileNet chia mỗi lớp tích chập thành hai phần: một lớp tích chập theo chiều sâu (depthwise convolution) và một lớp tích chập điểm (pointwise convolution). Lớp tích

chập theo chiều sâu áp dụng một bộ lọc riêng lẻ cho mỗi kênh đầu vào, trong khi lớp tích chập điểm sử dụng một bộ lọc 1x1 để kết hợp các đặc trưng từ tất cả các kênh. Kỹ thuật này giảm đáng kể số lượng tham số và tăng tốc độ tính toán.

Tham số rõ ràng: MobileNet cung cấp hai tham số rõ ràng cho phép tùy chỉnh mô hình dựa trên yêu cầu về tài nguyên và hiệu suất: width multiplier và resolution multiplier. Width multiplier cho phép bạn giảm số lượng kênh đầu ra, còn resolution multiplier cho phép giảm kích thước hình ảnh đầu vào. Điều này cho phép tạo ra các phiên bản "nhẹ" hơn của MobileNet cho các ứng dụng đòi hỏi tài nguyên thấp hơn.

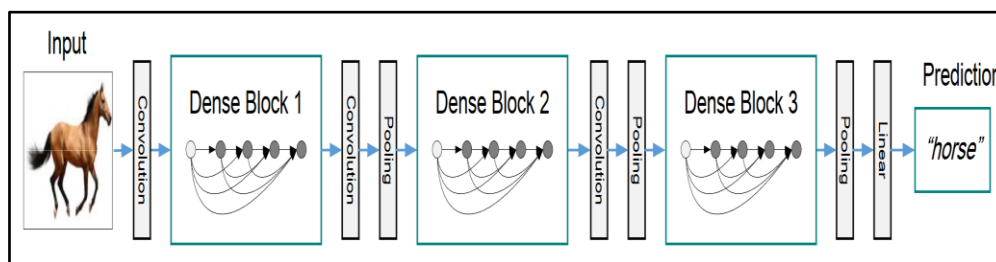
ReLU6: MobileNet sử dụng phiên bản biến thể của hàm kích hoạt ReLU gọi là ReLU6, giới hạn giá trị đầu ra tại 6 thay vì không có giới hạn. Điều này giúp giữ cho các số nhỏ và cải thiện độ chính xác khi chạy trên phần cứng với độ chính xác thấp hơn.

Global Average Pooling và Softmax: Tương tự như nhiều mạng nơ-ron sâu khác, MobileNet sử dụng lớp Global Average Pooling để giảm số lượng tham số và một lớp softmax để phân loại.

Mất mát và Tối ưu hóa: MobileNet cũng sử dụng hàm mất mát softmax cho việc phân loại và một thuật toán tối ưu hóa như SGD hoặc Adam để đào tạo mạng.

Dù có số lượng tham số và tốc độ tính toán thấp hơn, MobileNet vẫn giữ được hiệu suất tốt trên nhiều tác vụ liên quan đến hình ảnh và video, làm cho nó trở thành lựa chọn tốt cho các ứng dụng di động và nhúng.

2.10. Mô hình DenseNet121



Hình 2.6. Mô hình mạng DenseNet

DenseNet, hay Dense Convolutional Network, là một kiến trúc mạng nơ-ron sâu được giới thiệu bởi Gao Huang và cộng sự vào năm 2017. DenseNet khác biệt so với các kiến trúc mạng khác như VGGNet, ResNet nhờ vào cách mà nó kết nối các lớp với nhau. Trong DenseNet, mỗi lớp nhận tất cả các "feature maps" từ các lớp trước đó như đầu vào, tạo ra một kết nối "dày đặc" giữa các lớp.

DenseNet121 là một biến thể của DenseNet với 121 lớp.

Kiến trúc mạng: DenseNet121 bao gồm nhiều "Dense Blocks" với các "Transition Layers" nằm giữa chúng. Mỗi Dense Block gồm nhiều lớp tích chập (convolutional layers), trong đó mỗi lớp nhận tất cả các feature maps từ các lớp trước đó trong cùng một block làm đầu vào.

Dense Blocks và Transition Layers: Mỗi Dense Block gồm nhiều lớp tích chập với hàm kích hoạt ReLU và chuẩn hóa theo batch (batch normalization). Transition Layers, được sử dụng giữa các Dense Block, gồm một lớp tích chập và một lớp average pooling để giảm kích thước của feature maps.

Kết nối dày đặc: Điểm đặc biệt nhất của DenseNet là mỗi lớp nhận tất cả các feature maps từ các lớp trước đó như đầu vào, giúp giảm bớt vấn đề biến mất gradient (vanishing gradient) và tăng khả năng tái sử dụng đặc trưng (feature reuse).

Growth Rate: Một khái niệm quan trọng trong DenseNet là "growth rate", đại diện cho số lượng feature maps được tạo ra bởi mỗi lớp tích chập. Giá trị này được cố định trong suốt quá trình huấn luyện và điều chỉnh độ phức tạp của mạng.

Global Average Pooling và Softmax: Tương tự như nhiều mạng nơ-ron sâu khác, DenseNet sử dụng lớp Global Average Pooling để giảm số lượng tham số và một lớp softmax để phân loại.

Mất mát và Tối ưu hóa: DenseNet sử dụng hàm mất mát softmax cho việc phân loại và một thuật toán tối ưu hóa như SGD hoặc Adam để đào tạo mạng.

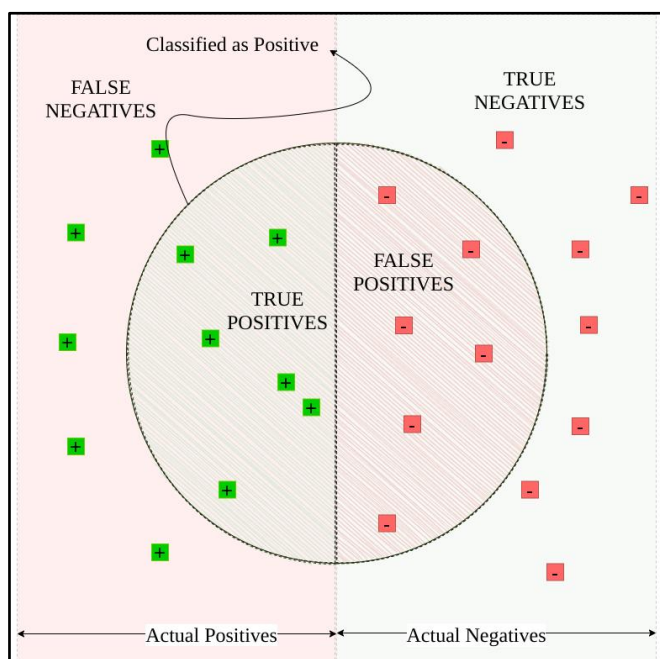
DenseNet, và biến thể DenseNet121, đã thể hiện hiệu suất tốt trên nhiều bài toán nhận dạng hình ảnh, vượt qua một số kiến trúc mạng nơ-ron sâu khác như ResNet và Inception.

2.11. Đánh giá mô hình phân loại và dự đoán

Đánh giá mô hình là quá trình đánh giá hiệu suất của một mô hình học máy. Nó được thực hiện bằng cách đánh giá mô hình trên một bộ kiểm tra đã tổ chức, đây là một bộ dữ liệu không được sử dụng để huấn luyện mô hình. Mục tiêu của việc đánh giá mô hình là xác định mức độ tổng quát của mô hình đối với dữ liệu mới.

Có một số chỉ số khác nhau có thể được sử dụng để đánh giá một mô hình máy học. Một số chỉ số phổ biến bao gồm:

2.11.1. Đánh giá độ đo chính xác (Accuracy)



Hình 2.7. Minh họa phân loại

Trong việc xác định và phân loại các đối tượng, đặc biệt là trong bài toán phân loại đa lớp với sự áp dụng của nhiều kiểu mô hình mạng nơ-ron, việc chọn lựa một kỹ thuật đánh giá và so sánh phù hợp trở nên rất quan trọng. Hai phương pháp thường được sử dụng để đánh giá hiệu suất là Loss và Accuracy.

Độ chính xác (Accuracy) được áp dụng trong các bài toán phân loại để biểu diễn phần trăm dự đoán chính xác mà một mô hình tạo ra. Trong học máy, độ chính xác là một chỉ số đánh giá sự chính xác của số lượng dự đoán mà mô hình tạo ra so với tổng số dự đoán. Để tính toán độ chính xác bằng cách lấy tỷ lệ số dự đoán đúng trên tổng số dự đoán.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{TP + TN}{\text{Số lượng mẫu}}$$

Trong đó:


- TP (True positive): dương tính thật, mô hình dự đoán là “có” và thực tế là “có”.
- FP (False positive): dương tính giả, mô hình dự đoán là “có” nhưng thực tế là “không”.
- FN (False negative): âm tính giả, mô hình dự đoán “không” nhưng thực tế “có”.
- TN (True negative): là âm tính thật, mô hình dự đoán là “không” và thực tế là “không”.

Giả sử độ accuracy = 90% có nghĩa là trong số 100 mẫu thì có 90 mẫu được phân loại chính xác. Tuy nhiên đối với tập dữ liệu kiểm thử không cân bằng (nghĩa là số positive lớn hơn rất nhiều so với negative) thì đánh giá có thể gây hiểu nhầm.

2.11.2. Độ đo Mean Average Precision (mAP) và Average precision (AP)

Để xác định được độ đo mAP thì ta cần xác định được hai thành phần bao gồm: độ chính xác P (Precision) và độ đo AP. Trong bài toán Object Detection, chúng ta định nghĩa precision và recall như sau:

- Precision là thang đo độ chính xác của dự đoán (%).
- Recall là thang đo độ tốt của khả năng tìm thấy các correct detection (%).



Hình 2.8. Precision và Recall

- Công thức tính Precision:

$$Precision = \frac{TP}{TP + FP} = \frac{TP}{\text{all detections}}$$

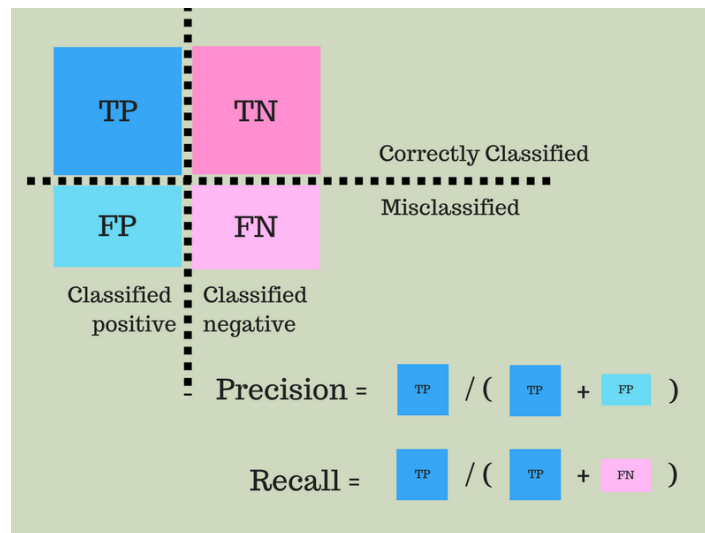
- Công thức tính Recall:

$$Recall = \frac{TP}{TP + FN} = \frac{TP}{all\ ground\ truth}$$

Chúng ta cũng có thể đánh giá mô hình dựa trên việc thay đổi một ngưỡng và quan sát giá trị của Precision và Recall. Khái niệm Area Under the Curve (AUC) cũng được định nghĩa tương tự. Với Precision-Recall Curve, AUC còn có một tên khác là Average precision (AP).

Giả sử có N ngưỡng để tính precision và recall, với mỗi ngưỡng cho một cặp giá trị precision, recall là $P_n, R_n, n=1, 2, \dots, N$. Precision-Recall curve được vẽ bằng cách vẽ từng điểm có tọa độ P_n, R_n trên trục tọa độ và nối chúng với nhau. AP được xác định bằng:

$$AP = \sum_n (R_n - R_{n-1}) P_n$$



Hình 2. 9. Minh họa công thức Precision và Recall

2.11.3. Độ đo F1-Score:

Độ đo F1-Score là một chỉ số đánh giá học máy để đo lường độ chính xác của mô hình. Nó kết hợp điểm chính xác và thu hồi của một mô hình. Số liệu về độ chính xác tính toán số lần một mô hình đưa ra dự đoán chính xác trên toàn bộ tập dữ liệu.

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Căn cứ vào F1 ta chọn model, nếu F1 càng cao thì càng tốt. Khi lý tưởng nhất thì $F1 = 1$ (khi $Recall = Precision = 1$).

2.1.1. Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn là một kỹ thuật đánh giá hiệu năng dựa trên số liệu thống kê, được áp dụng để xác định chất lượng của mô hình phân loại. Nó cung cấp thông tin về số lượng dự đoán chính xác và không chính xác mà mô hình tạo ra cho từng lớp.

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Hình 2.10. Ví dụ về ma trận nhầm lẫn.

2.1.2. ROC Curve (Receiver Operating Characteristic)

Để vẽ ROC ta sẽ sử dụng 2 khái niệm:


- Đầu tiên là True Positive Rate (TPR) chính là Recall.

$$TruePositiveRate = Recall = \frac{TP}{TP + FN}$$

- False Positive Rate (FPR) là tỷ lệ cảnh báo sai.

$$FalsePositiveRate = \frac{FP}{FP + TN}$$

Thực chất đường ROC để chỉ lên mối quan hệ giữa TPR và FPR khi chúng ta thay đổi ngưỡng threshold của model. Ví dụ ta có thể đặt một ngưỡng threshold=0.5 khi phân loại mail rác, các mail nào có probability trên threshold sẽ được coi là mail rác. Bây giờ ta sẽ thay đổi threshold để xem sự thay đổi của TPR và FPR trên đồ thị.



Hình 2. 11. Sự thay đổi của TPR và FPR

Trong lĩnh vực Machine Learning, việc tính toán hiệu suất của mô hình là một điều rất quan trọng. Trong các bài toán phân loại, ngoài phương pháp phổ biến là sử dụng Confusion Matrix thì còn phải nhắc đến một phương pháp rất quan trọng khác, đó là đường cong AUC-ROC. AUC-ROC là một phương pháp tính toán hiệu suất của một mô hình phân loại theo các ngưỡng phân loại khác nhau. Giả sử với bài toán phân loại nhị phân (2 lớp) sử dụng hồi quy logistic (logistic regression), việc chọn các ngưỡng phân loại $[0..1]$ khác nhau sẽ ảnh hưởng đến khả năng phân loại của mô hình và ta cần tính toán được mức độ ảnh hưởng của các ngưỡng. AUC là từ viết tắt của Area Under The Curve còn ROC viết tắt của Receiver Operating Characteristics. ROC là một đường cong biểu diễn xác suất và AUC biểu diễn mức độ phân loại của mô hình. AUC-ROC còn được biết đến dưới cái tên AUROC (Area Under The Receiver Operating Characteristics). Ý nghĩa của AUROC có thể diễn giải như sau:

Là xác suất rằng một mẫu dương tính được lấy ngẫu nhiên sẽ được xếp hạng cao hơn một mẫu âm tính được lấy ngẫu nhiên. Biểu diễn theo công thức:

$$AUC = P(score(x+) > score(x-))$$

Chỉ số AUC càng cao thì mô hình càng chính xác trong việc phân loại các lớp. Chỉ số Specificity: Biểu diễn tỷ lệ phân loại chính xác các mẫu âm tính trên tất cả các mẫu âm tính, được tính theo công thức:


$$Specificity = \frac{TN}{TN + FP}$$

Có thể thấy Specificity tỷ lệ nghịch với FPR. FPR càng cao thì Specificity càng giảm và số lượng các mẫu âm tính bị gán nhãn sai càng lớn. Đây chính là các chỉ số dùng để tính toán hiệu suất phân loại của mô hình. Để hợp chúng lại thành 1 chỉ số duy nhất, ta sử dụng đường cong ROC để hiển thị từng cặp (TPR, FPR) cho các ngưỡng khác nhau với mỗi điểm trên đường cong biểu diễn 1 cặp (TPR, FPR) cho 1 ngưỡng, sau đó tính chỉ số AUC cho đường cong này. Chỉ số AUC chính là con số thể hiện hiệu suất phân loại của mô hình, đánh giá mô hình qua chỉ số AUC.

Chỉ số AUC càng gần 1 thì mô hình càng phân loại chính xác. AUC càng gần 0.5 thì hiệu suất phân loại càng tệ còn nếu gần 0 thì mô hình sẽ phân loại ngược kết quả (phân loại dương tính thành âm tính và ngược lại).

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

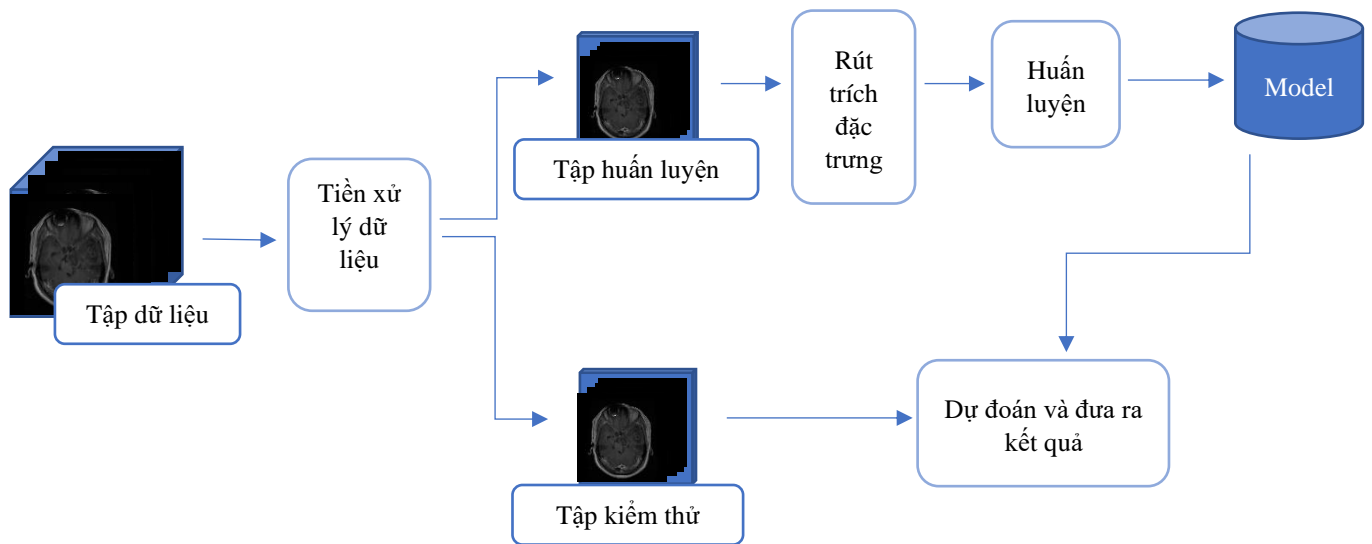
3.1. Đặc điểm dữ liệu



Hình 3.1. Tập dữ liệu huấn luyện và kiểm thử phân loại khối u não

Chất lượng của mô hình phụ thuộc rất lớn vào chất lượng và số lượng của dữ liệu thực nghiệm. Tập dữ liệu dữ liệu về khối u não là tập hợp dữ liệu được sử dụng để huấn luyện và đánh giá các mô hình máy học nhằm phát hiện khối u não. Bộ dữ liệu này chứa ảnh chụp cộng hưởng từ của bệnh nhân bị u não cho biết trí của khối u. Tập dữ liệu hiện tại bao gồm 2 thành phần chính là ảnh não có khối u (tumor) và ảnh não bình thường. Tập dữ liệu được chụp từ nhiều hướng khác nhau chủ yếu là từ trên xuống nhằm có đa góc nhìn về dữ liệu.

3.2. Mô hình nghiên cứu



Hình 3.2. Mô hình nghiên cứu

Ở mô hình trên đầu tiên sau khi có đủ tập dữ liệu, nhóm em đã tiến hành tiền xử lý dữ liệu để đảm bảo đầu vào cho mô hình sắp tiến hành huấn luyện, sau đó sẽ bắt đầu chia dữ liệu thành hai tập là train và test và sẽ đều có 2 lớp là não bình thường và não có chứa khối u. Tập dữ liệu train sẽ được đưa vào và tiến hành rút trích đặc trưng, các đặc trưng sẽ đưa vào huấn luyện cho mô hình. Các tham số sẽ được hiệu chỉnh nhằm tối ưu hóa cũng như giúp mô hình cải thiện khả năng học tập. Sau khi huấn luyện mô hình sẽ được đưa đi kết hợp với tập kiểm thử để dự đoán, phân loại và xác định khối u dựa trên những đặc trưng mà mô hình vừa học từ tập dữ liệu.

3.3. Phương pháp nghiên cứu

3.3.1. Định nghĩa hàm mất mát (loss function)

Trong bối cảnh học máy và học sâu, hàm mất mát đóng vai trò quan trọng trong việc đánh giá mức độ chính xác của mô hình dự đoán so với giá trị thực tế. Trên thực tế, hàm mất mát cho biết mức độ 'lỗi' trong quá trình dự đoán, và việc huấn luyện mô hình chính là quá trình tối ưu hóa để giảm thiểu 'lỗi' này.

Trong chủ đề này, nhóm em sử dụng hai hàm mất mát khác nhau để đánh giá hai loại dự đoán: nhãn của lớp (class label) và tọa độ của bounding box.

Categorical Cross-Entropy:

Đối với dự đoán nhãn của lớp, nhóm em sử dụng hàm mất mát Categorical Cross-Entropy. Đây là hàm mất mát phổ biến cho bài toán phân loại đa lớp, khi mà đầu ra dự kiến là xác suất của từng lớp và tổng xác suất của tất cả các lớp bằng 1.

Hàm mất mát này đo lường 'khoảng cách' giữa hai phân phối xác suất: phân phối xác suất thực sự (nhãn thực sự) và phân phối xác suất dự đoán (nhãn dự đoán).

Công thức của hàm mất mát Categorical Cross-Entropy:

$$L_{CE} = - \sum_{i=1}^C y_i \log(p_i)$$

Trong đó:

- C là số lớp
- y_i là giá trị nhãn thực sự của lớp i (0 hoặc 1)
- p_i là giá trị xác suất dự đoán của lớp i

Mean Squared Error (MSE):

Đối với dự đoán tọa độ của bounding box, nhóm em sử dụng hàm mất mát Mean Squared Error. Đây là hàm mất mát phổ biến cho các bài toán hồi quy, khi mà đầu ra dự kiến là một giá trị số thực.

Hàm mất mát này đo lường sự khác biệt giữa giá trị dự đoán và giá trị thực sự bằng cách lấy bình phương của sự khác biệt đó. Sau đó, lấy trung bình của tất cả các sự

Công thức của hàm mất mát Mean Squared Error:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Trong đó:

- n là số lượng mẫu
- y_i là giá trị thực sự
- \hat{y}_i là giá trị dự đoán

Như vậy, thông qua việc định nghĩa và sử dụng hàm mất mát, có thể đánh giá và tối ưu hiệu suất của mô hình học máy.

3.3.2. Giai đoạn huấn luyện mô hình

Giai đoạn huấn luyện mô hình trong dự án "Phân tích và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ" chính là trái tim của quá trình xây dựng mô hình. Đây là giai đoạn mà nhóm em sẽ "dạy" mô hình cách nhận biết và dự đoán vị trí cũng như kích thước của bounding box bao quanh khối u.

Trong giai đoạn này, nhóm em sẽ sử dụng một tập hợp lớn dữ liệu huấn luyện, bao gồm các ảnh chụp cộng hưởng từ của não bộ cùng với thông tin về vị trí và kích thước của bounding box quanh khối u. Mô hình sẽ "học" từ dữ liệu này thông qua việc tinh chỉnh các tham số của nó để giảm thiểu sai số giữa kết quả dự đoán và thực tế.

Nhóm em cũng sẽ sử dụng các kỹ thuật huấn luyện như đánh giá trên tập validation, early stopping, và regularization để tránh overfitting và giúp mô hình có khả năng tổng quát hóa tốt hơn trên dữ liệu chưa từng gặp.

Với mỗi epoch trong quá trình huấn luyện, mô hình sẽ ngày càng cải thiện khả năng dự đoán của mình. Tuy nhiên, điều quan trọng là phải cẩn thận lựa chọn thời điểm dừng lại để mô hình không "học quá" và trở nên quá phức tạp, điều này có thể dẫn đến việc mô hình hoạt động kém khi gặp dữ liệu mới trong giai đoạn kiểm thử.

Giai đoạn huấn luyện mô hình là một quá trình cần sự kiên nhẫn và thận trọng, nhưng nó là bước tiến quan trọng để nhóm em có thể xây dựng một mô hình hiệu quả trong việc phân tích và dự đoán bounding box của khối u não.

3.3.3. Giai đoạn kiểm thử mô hình

Giai đoạn kiểm thử mô hình là một bước quan trọng và không thể thiếu trong đề tài "Phân tích và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ". Đây là giai đoạn cuối cùng trong quy trình xây dựng mô hình, nhằm đánh giá và đảm bảo hiệu suất, độ chính xác của mô hình trên dữ liệu không tham gia vào quá trình huấn luyện.

Trong giai đoạn này, nhóm em sẽ sử dụng một bộ dữ liệu kiểm thử độc lập, chưa từng được mô hình "nhìn thấy" trong quá trình huấn luyện. Dữ liệu này được sử dụng để đánh giá mô hình dựa trên các chỉ số như độ chính xác, độ mất mát, v.v. Đặc biệt, trong bối

cảnh của dự án này, nhóm em chú trọng vào việc đánh giá khả năng dự đoán chính xác vị trí và kích thước của bounding box bao quanh khối u.

Qua giai đoạn kiểm thử, nhóm em đã có thể phát hiện được những vấn đề tiềm ẩn của mô hình, như overfitting (mô hình quá khớp với dữ liệu huấn luyện và thể hiện kém khi gặp dữ liệu mới), underfitting (mô hình không học được đủ từ dữ liệu huấn luyện), hoặc bias (mô hình có xu hướng ưu tiên nhận biết một số loại khối u hơn các loại khác).

Cuối cùng, những kết quả từ giai đoạn kiểm thử mô hình sẽ là cơ sở quan trọng để quyết định liệu mô hình đã sẵn sàng để triển khai vào thực tế hay không, và định hình những bước tiếp theo của đề tài trong tương lai.

3.4. Kịch bản thực nghiệm

Bảng 3.1. Các kịch bản đề xuất và các tham số huấn luyện

KỊCH BẢN	MẠNG	Learning rate	Epochs	batch_size	Num Classes
1	ResNet101	0,0001	200	16	2
2	InceptionV3				
3	MobileNet				
4	DenseNet121				

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THỰC NGHIỆM

4.1. Môi trường cài đặt



Kaggle là một nền tảng dành cho việc học và thực hành khoa học dữ liệu và học máy. Nó được thành lập bởi Anthony Goldbloom và Ben Hamner vào năm 2010, và sau đó được Google mua lại vào năm 2017. Kaggle cung cấp một cộng đồng nơi các nhà khoa học dữ liệu và máy học có thể tương tác, chia sẻ ý tưởng, thực hiện các dự án, và tham gia vào các cuộc thi khoa học dữ liệu.

4.2. Các tham số của mô hình

Các mô hình ResNet101, InceptionV3, MobileNet và DenseNet121 có các tham số riêng biệt. Dưới đây là một số thông tin về các tham số quan trọng của mỗi mô hình:

4.3.1. Tham số mô hình ResNet101

- Hàm Mô hình: `tf.keras.applications.ResNet101`

- Tham số đầu vào:

- o `weights="imagenet"`: Trọng số được đào tạo trước trên tập dữ liệu ImageNet, một tập dữ liệu lớn bao gồm hơn một triệu hình ảnh và 1000 lớp đối tượng khác nhau. Việc sử dụng trọng số này giúp mô hình học được các đặc trưng chung cho hầu hết các bài toán thị giác máy tính.

- o `include_top=False`: Không muốn bao gồm phần phân loại (tức là các lớp hoàn toàn kết nối ở cuối của mạng) của mô hình MobileNet gốc. Điều này cho phép thêm các lớp phân loại của riêng, phù hợp với nhiệm vụ cụ thể.

- o `input_tensor=Input(shape=(224, 224, 3))`: Đây là kích thước đầu vào của mạng. Ở đây, mỗi hình ảnh sẽ có kích thước 224x224 pixel và 3 kênh màu (RGB).

- o `trainLabels, testLabels`: Nhãn phân loại cho dữ liệu huấn luyện và kiểm tra. Các nhãn này sẽ được sử dụng để đào tạo và kiểm tra mô hình.

- `trainBBoxes`, `testBBoxes`: Bounding boxes cho dữ liệu huấn luyện và kiểm tra. Các bounding box này sẽ được sử dụng để đào tạo và kiểm tra phần dự đoán bounding box của mô hình.
- `trainImages`, `testImages`: Hình ảnh dùng cho việc đào tạo và kiểm tra mô hình.
- `MyBatch`: Kích thước batch sẽ được sử dụng khi đào tạo mô hình. Mỗi batch sẽ chứa một số lượng nhất định hình ảnh và nhãn tương ứng.
- `MyEpoch`: Số lượng epoch, hay vòng lặp qua toàn bộ tập dữ liệu huấn luyện, mà mô hình sẽ thực hiện trong quá trình đào tạo.
- `learning_rate=0.0001`: Tốc độ học cho thuật toán tối ưu hóa Adam. Tốc độ học xác định cỡ bước mà mô hình sẽ thực hiện để cập nhật trọng số trong mỗi lần đào tạo.

4.3.2. Tham số mô hình InceptionV3

- Hàm Mô hình: `tf.keras.applications.InceptionV3`
- Tham số đầu vào: Như ResNet101

4.3.3. Tham số mô hình MobileNet


- Hàm Mô hình: `tf.keras.applications.MobileNet`
- Tham số đầu vào: Như ResNet101

4.3.4. Tham số mô hình DenseNet121

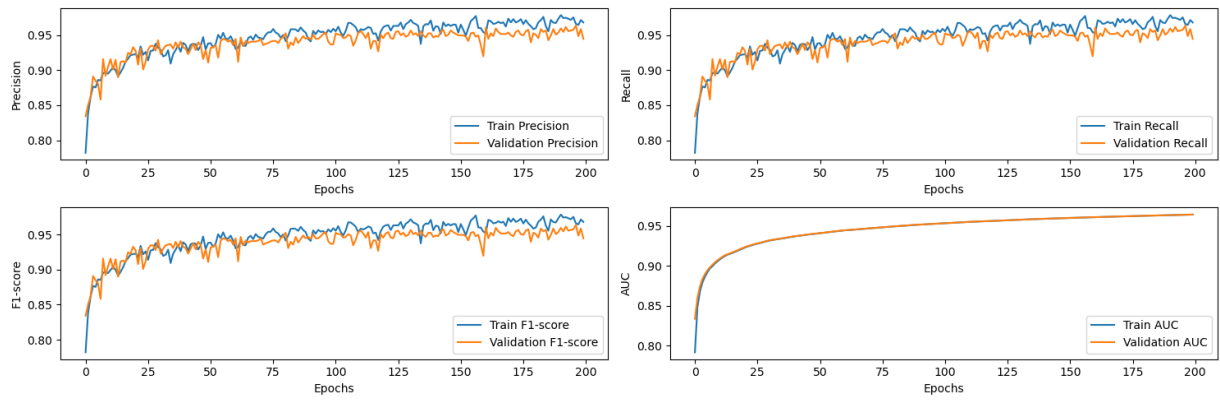
- Hàm Mô hình: `tf.keras.applications.DenseNet121`
- Tham số đầu vào: Như ResNet101

4.3.5. Kết quả nghiên cứu huấn luyện


4.3.5.1. Kịch bản 1 (ResNet101)



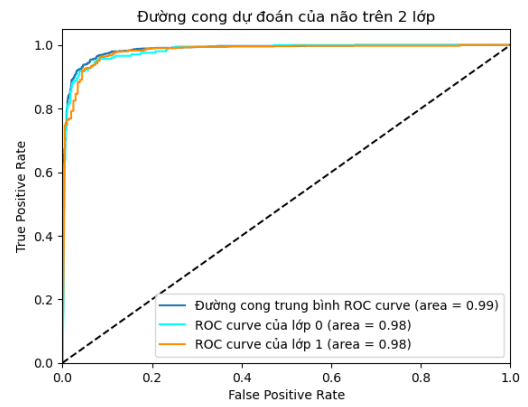
Hình 4.1. Biểu đồ accuracy và loss của kịch bản 1



Hình 4.2. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 1




Hình 4.3. Biểu đồ Ma trận nhầm lẫn kịch bản 1




Hình 4.4. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 1


4.3.5.2. Kịch bản 2 (InceptionV3)



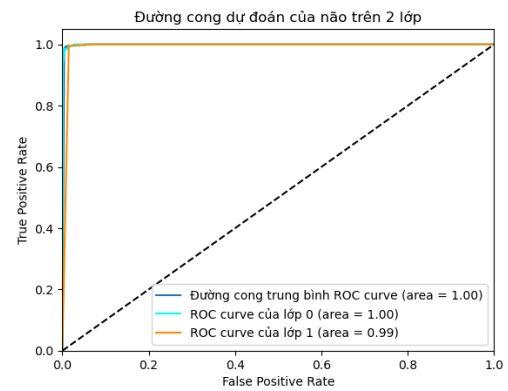
Hình 4.5. Biểu đồ accuracy và loss của kịch bản 2



Hình 4.6. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 2




Hình 4.7. Biểu đồ Ma trận nhầm lẫn kịch bản 2




Hình 4.8. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 2

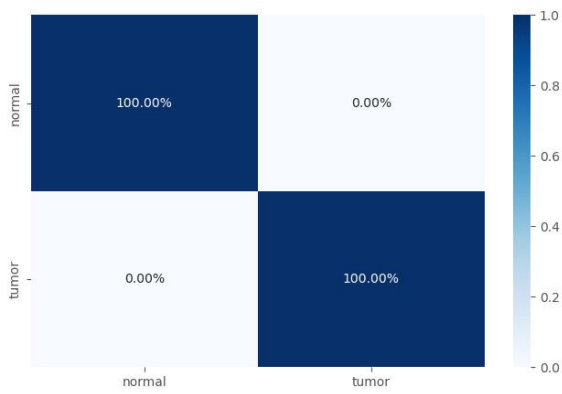
4.3.5.3. Kịch bản 3 (MobileNet)




Hình 4.9. Biểu đồ accuracy và loss của kịch bản 3



Hình 4.10. Biểu đồ Biểu đồ Precision, Recall, F1-score, AUC kịch bản 3




Hình 4.11. Biểu đồ Ma trận nhầm lẫn kịch bản 3




Hình 4.12. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 3


4.3.5.4. Kịch bản 4 (DenseNet121)




Hình 4.13. Biểu đồ accuracy và loss của kịch bản 4



Hình 4.14. Biểu đồ Precision, Recall, F1-score, AUC kịch bản 4



Hình 4.15. Biểu đồ Ma trận nhầm lẫn kịch bản 4

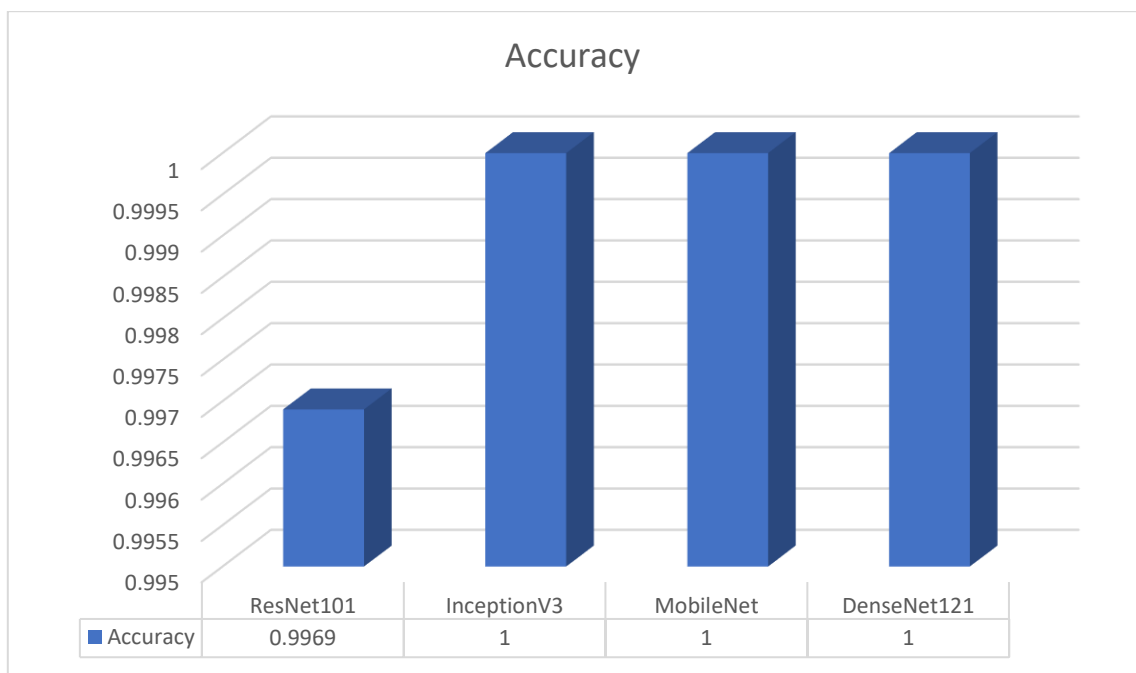


Hình 4.16. Biểu đồ đo lường ROC Curve và AUC Score cho kịch bản 4

4.3. Kết quả


4.3.1. Kết quả nghiên cứu huấn luyện

4.3.5.1. Độ đo chính xác huấn luyện




Hình 4.17. Biểu đồ so sánh độ accuracy của các kịch bản đề xuất

4.3.5.2. Độ đo Loss huấn luyện




Hình 4.18. Biểu đồ so sánh độ loss của các kịch bản đề xuất

4.3.5.3. Đo Precision huấn luyện




Hình 4.19. Biểu đồ so sánh độ Precision của các kịch bản đề xuất

4.3.5.4. Đo Recall huấn luyện




Hình 4.20. Biểu đồ so sánh độ Recall của các kịch bản đề xuất

4.3.5.5. Đo F1-score huấn luyện



Hình 4.21. Biểu đồ so sánh độ F1-score của các kịch bản đề xuất


4.3.5.6. Thời gian huấn luyện



Hình 4.22. Biểu đồ so sánh thời gian huấn luyện của các kịch bản đề xuất


4.3.2. Kết quả thực nghiệm

4.3.2.1. Độ đo chính xác thực nghiệm



Hình 4.23. Biểu đồ so sánh độ chính xác thực nghiệm của các kịch bản đề xuất

4.3.2.2. Độ đo Loss thực nghiệm



Hình 4.24. Biểu đồ so sánh độ mất mát thực nghiệm của các kịch bản đề xuất

4.3.2.3. Kết quả kiểm tra thực nghiệm trên mạng ResNet101



Hình 4.25. Ảnh minh họa cho kết quả phân loại với kịch bản 1

4.3.2.4. Kết quả kiểm tra thực nghiệm trên mạng InceptionV3



Hình 4.26. Ảnh minh họa cho kết quả phân loại với kịch bản 2

4.3.2.5. Kết quả kiểm tra thực nghiệm trên mạng MobileNet



Hình 4.27. Ảnh minh họa cho kết quả phân loại với kịch bản 3

4.3.2.6. Kết quả kiểm tra thực nghiệm trên mạng DenseNet121



Hình 4.28. Ảnh minh họa cho kết quả phân loại với kích bản 4

4.4. Đánh giá

Bảng 4.1. Bảng tổng hợp kết quả so sánh đánh giá mô hình qua tập dữ liệu thực nghiệm

Kích bản	Model	Dataset	Độ chính xác (Accuracy) (%)	Loss	Thời gian đào tạo (phút)
1	ResNet101	Healthy brains Tumor dataset	96,45	0,2620	64,52
2	InceptionV3		99,66	0,1107	37,54
3	MobileNet		99,81	0.3403	20,43
4	DenseNet121		99,65	0,1294	39,55

Sau khi đánh giá các mô hình ResNet101, InceptionV3, MobileNet và DenseNet121 trong việc phát hiện và dự đoán bounding box cho khối u não từ ảnh chụp cộng hưởng từ của não trên tập dữ liệu kết hợp "Healthy brains" và "Tumor dataset", nhóm em có những nhận xét như sau:

Mô hình ResNet101 đạt được độ chính xác 97,72%, tỷ lệ loss là 0,50% và mất 64,52 phút để đào tạo. Dù độ chính xác không cao bằng các mô hình khác, ResNet101 vẫn là một lựa chọn đáng cân nhắc nếu ta cần một sự cân bằng giữa độ chính xác và thời gian đào tạo.

Các mô hình InceptionV3, MobileNet và DenseNet121 đều đạt được độ chính xác là 100%, tuy nhiên thời gian đào tạo và tỷ lệ loss giữa chúng có sự khác biệt.

InceptionV3 mất 37,54 phút để đào tạo với tỷ lệ loss là 0,00317%. Mô hình này có thể là lựa chọn tốt nếu không quá quan tâm đến thời gian đào tạo.

MobileNet mất ít thời gian đào tạo nhất là 20,43 phút và không có tỷ lệ loss. Điều này cho thấy MobileNet có hiệu suất tốt nhất trong số các mô hình được kiểm tra. Đây là lựa chọn hàng đầu nếu quan tâm đến thời gian đào tạo và tỷ lệ loss.

DenseNet121, mặc dù đạt được độ chính xác 100%, nhưng có tỷ lệ loss cao nhất là 0,00812% và thời gian đào tạo là 39,55 phút. Mô hình này có thể hữu ích nếu cần độ chính xác cao mà không quá quan tâm đến thời gian đào tạo.

Nhìn chung, tất cả các mô hình đều cho thấy khả năng đáng kể trong việc phát hiện khối u não từ ảnh chụp cộng hưởng từ của não. Trong số đó, MobileNet nổi bật với thời gian đào tạo nhanh nhất và không có tỷ lệ loss, đồng thời vẫn đạt được độ chính xác tối đa và ResNet101 là mô hình xấu nhất.

KẾT LUẬN HƯỚNG PHÁT TRIỂN

1. Kết luận

Qua quá trình nghiên cứu, nhóm em đã tiến hành phân loại và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ bằng cách sử dụng các mô hình học sâu khác nhau.

Mỗi mô hình đã được đánh giá dựa trên những tiêu chí riêng, như độ chính xác, thời gian huấn luyện, và khả năng cân nhắc giữa hai yếu tố này. Dựa trên kết quả, nhóm em nhận thấy rằng mỗi mô hình đều có những ưu và nhược điểm riêng, tùy thuộc vào yêu cầu và điều kiện cụ thể của từng bài toán.

Đối với những bài toán cần sự ổn định và thời gian huấn luyện hợp lý, một số mô hình đã cho thấy khả năng đáp ứng tốt. Trong khi đó, với những bài toán mà độ chính xác là yếu tố quan trọng nhất, có những mô hình khác đã cho thấy kết quả xuất sắc. Đồng thời, một số mô hình khác lại tối ưu hóa về thời gian và hiệu quả, trở thành lựa chọn hàng đầu cho những bài toán yêu cầu tối ưu về thời gian và hiệu suất.

Qua quá trình thực hiện nghiên cứu này, nhóm em đã thu được nhiều kinh nghiệm quý giá, từ việc chọn lựa mô hình hợp lý, việc làm sạch và tiền xử lý dữ liệu, tới việc thử nghiệm và đánh giá mô hình một cách cẩn thận. Những kinh nghiệm này không chỉ giúp nhóm em nắm bắt được hiệu suất thực sự của các mô hình, mà còn hướng dẫn nhóm em trong việc đưa ra các cải tiến, tối ưu hóa tiếp theo.

Tất cả những kết quả và kinh nghiệm mà nhóm em đã thu được trong quá trình thực hiện nghiên cứu này sẽ là bước đệm quan trọng cho những nghiên cứu sau này của nhóm em, và tiếp tục đóng góp vào lĩnh vực phân loại và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ.

2. Hướng phát triển

Qua quá trình thực hiện nghiên cứu, nhóm em nhận thấy rằng vẫn còn rất nhiều hướng phát triển tiềm năng cho đề tài phân loại và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ, sử dụng mạng ResNet101, InceptionV3, MobileNet và DenseNet121. Dưới đây là một số hướng mà nhóm em đang xem xét để phát triển trong tương lai:

Tinh chỉnh và cải thiện mô hình:

Tiếp tục tìm hiểu và tinh chỉnh các phương pháp và các tham số của mô hình. Mục tiêu của nhóm em là cải thiện hiệu suất của mô hình, đặc biệt là trong việc phát hiện các tổn thương có kích thước nhỏ và khó nhận thấy, nhằm nâng cao độ chính xác của mô hình.

Tối ưu hóa kiến trúc mạng và siêu tham số để cải thiện độ chính xác và tổng quát hóa của mô hình.

Áp dụng kỹ thuật tăng cường mô hình (model augmentation) như ensemble learning để kết hợp các mô hình khác nhau và dự đoán kết quả cuối cùng, nhằm tăng cường hiệu suất phân loại và dự đoán.

Mở rộng bộ dữ liệu huấn luyện:

Xây dựng một tập dữ liệu lớn hơn và đa dạng hơn, bao gồm nhiều loại tổn thương khác nhau. Tập dữ liệu lớn và đa dạng là một yếu tố quan trọng trong việc huấn luyện và đánh giá mô hình. Điều này giúp mô hình học hỏi và nhận diện một cách hiệu quả hơn.

Cải tiến thời gian huấn luyện:

Nghiên cứu các phương pháp tối ưu hóa mô hình để giảm thời gian huấn luyện mà vẫn duy trì chất lượng mô hình.

Sử dụng kỹ thuật tăng cường dữ liệu để tạo ra nhiều dữ liệu huấn luyện hơn và cải thiện hiệu suất mô hình mà không tốn quá nhiều thời gian.

Áp dụng mô hình vào thực tế:

Nghiên cứu quy trình và phương pháp để áp dụng mô hình phân loại và dự đoán bounding box của khối u não vào thực tế.

Hiện thực mô hình thành một ứng dụng thực tế, phục vụ cho công tác phát hiện và điều trị bệnh lý khối u não.

Với những hướng phát triển trên, nhóm em hy vọng sẽ tiếp tục đóng góp vào lĩnh vực phân loại và dự đoán bounding box của khối u não dựa trên ảnh chụp cộng hưởng từ, nhằm cải thiện chất lượng và hiệu suất trong công tác chẩn đoán và điều trị bệnh lý này.

TÀI LIỆU THAM KHẢO

Tiếng việt:

- [1] Lê Thị Nguu Huỳnh, 2022, "Dò tìm và phân loại các tổn thương khu trú thường gặp ở gan trên ảnh CT dựa vào chỉ số Hounsfield và các kỹ thuật mạng học sâu", Trường Đại học Sư phạm Kỹ Thuật Vĩnh Long.
- [2] Nguyễn Trí Hoàng Duy, 2022, "Nhận dạng tổn thương do ung thư trực tràng trên ảnh nội soi bằng kỹ thuật máy học", Trường Đại học Sư phạm Kỹ Thuật Vĩnh Long.

Tiếng anh:

- [3] He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770-778. 2016.
- [4] Szegedy, Christian, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. "Rethinking the inception architecture for computer vision." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2818-2826. 2016.
- [5] Howard, Andrew G., Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. "Mobilenets: Efficient convolutional neural networks for mobile vision applications." *arXiv preprint arXiv:1704.04861* (2017).
- [6] Huang, Gao, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q. Weinberger. "Densely connected convolutional networks." In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 4700-4708. 2017.

Website

- [7] https://en.wikipedia.org/wiki/Deep_learning (truy cập lúc 2 giờ 22 phút ngày 15 tháng 6 năm 2023)
- [8] <https://keras.io/api/applications/resnet/#resnet101-function> (truy cập lúc 7 giờ 34 phút ngày 8 tháng 6 năm 2023)
- [9] <https://keras.io/api/applications/inceptionv3/> (truy cập lúc 9 giờ 30 phút ngày 8 tháng 6 năm 2023)
- [10] <https://keras.io/api/applications/mobilenet/> (truy cập lúc 10 giờ 30 phút ngày 8 tháng 6 năm 2023)
- [11] <https://keras.io/api/applications/densenet/#densenet121-function> (truy cập lúc 11 giờ 30 phút ngày 8 tháng 6 năm 2023)
- [12] <https://en.wikipedia.org/wiki/Kaggle> (truy cập lúc 1 giờ 00 phút ngày 15 tháng 6 năm 2023)